

Universitatea  
Transilvania  
din Brașov

FACULTATEA DE INGINERIE ELECTRICĂ  
ȘI ȘTIINȚA CALCULATOARELOR

# PROIECT DE DIPLOMĂ

Conducător științific:

Conf. Habil. Dr. Ing. COCIAS Tiberiu Teodor

Absolvent:

JUGARIU MATTIAS MARIAN

BRAȘOV, 2025

Departamentul de Automatică și Tehnologia Informației  
Programul de studii: Robotică

*Jugariu Mattias-Marian*

# Scanner 3D

**Conducător științific:**

Conf. Habil. Dr. Ing. *COCIAȘ Tiberiu Teodor*

Brașov, 2025

## FIȘA PROIECTULUI DE DIPLOMĂ

<b>Universitatea Transilvania din Brașov</b>	Proiect de diplom nr. ....
Facultatea <b>Inginerie Electrică și Știința Calculatoarelor</b>	
Departamentul <b>Automatică și Tehnologia Informației</b>	Viza facultății
Programul de studii <b>Robotică</b>	Anul universitar <b>2024 - 2025</b>
Candidat <b>Jugariu Mattias-Marian</b>	Promoția <b>2025</b>
Conducător științific <b>Conf.dr.ing. Tiberiu Teodor COCIAȘ</b>	
<b>PROIECT DE DIPLOMĂ</b>	
Titlul lucrării: <b>Scanner 3D</b>	
Problemele principale tratate: 1. Studiul actual al cercetării 2. Descrierea sistemului 3. Implementarea software 4. Proiectarea și simularea sistemului	
Locul și durata practicii: Corp V, Laborator V III 15, 60 ore	
Bibliografie: Bibliografia recomandată: [1] Macesanu G, Cocias T.T., Grigorescu S.M. , Sisteme de vedere artificială : Îndrumar de laborator, 2013 [2] Massimo Banzi, Getting Started with Arduino (Make: Projects), 2009 [3] Paul ViolaMichael J. Jones, Robust Real-Time Face Detection , 2004	
Aspecte particulare: Nu sunt	
Primit tema la data de: <b>02 Octombrie 2024</b>	
Data predării lucrării: <b>21 Iunie 2025</b>	
Director departament, <b>Prof. Dr. ing. Sorin-Aurel MORARU</b>	Conducător științific, <b>Conf.dr.ing. Tiberiu Teodor COCIAȘ</b> 
Candidat, <b>JUGARIU MATTIAS MARIAN</b> 	

PROIECT DE DIPLOMĂ – VIZE –		
Data vizei	Capitole/ problemele analizate	Semnătura conducătorului științific
16.12.2024	Studiu asupra stadiului actual în domeniul și tema vizată; livrabil: raport	
07.03.2025	Proiectare / Arhitecturi, tehnologii, limbaje de programare, algoritmi de utilizat etc; livrabil: raport, document editat	
25.04.2025	Demonstrator / Proof of Concept / Aplicație; livrabil: prototip	
03.06.2025	Documentație; livrabil: document în formatul de proiect de pe situl ATI	
19.06.2025	Rezultat raport Turnitin: Procent global: 2%, Procent maxim dintr-o singură sursă: 1%	
APRECIEREA ȘI AVIZUL CADRULUI DIDACTIC ÎNDRUMĂTOR		
<p>Lucrarea îndeplinește criteriile de calitate pentru a putea fi susținută. Candidatul a prezentat progres remarcabil de-a lungul întregului semestru. Rezultatele experimentale obținute m-au convins să îmi dau acordul pentru susținerea lucrării de licență în cadrul sesiunii Iunie 2025.</p>		
Data: 21.06.2025	ADMIS pentru susținere/ RESPINS	CONDUCĂTOR ȘTIINȚIFIC Conf.dr.ing. Tiberiu Teodor COCIAS
AVIZUL DIRECTORULUI DE DEPARTAMENT		
Data:	ADMIS pentru susținere/ RESPINS	Director departament Prof. Dr. ing. Sorin-Aurel MORARU
SUSȚINEREA PROIECTULUI DE DIPLOMĂ		
Sesiunea <b>Vara 2025</b>		
Rezultatul susținerii	PROMOVAT cu media:	
	RESPINS cu refacerea lucrării	
	RESPINS fără refacerea lucrării	
PREȘEDINTE COMISIE Prof.dr.ing. Sorin-Mihai GRIGORESCU		

# Cuprins

## Cuprins

---

1.	Introducere .....	6
1.1	Contextul lucrării.....	6
1.2	Stadiul actual .....	6
1.3	Obiectivul lucrării .....	7
2.	Noțiuni fundamentale.....	9
3.	Scanner 3D .....	20
3.1	Prezentare generală .....	20
3.2	Sistem de achiziție.....	20
3.2.1	Design Hardware .....	20
3.2.2	Componente utilizate.....	23
3.2.3	Schema Electrică .....	29
3.2.4	Limite dimensionale de scanare .....	30
3.2.5	Interfața de control .....	31
3.2.6	Achiziția de date .....	33
3.2.7	Transferul de date .....	36
3.3	Sistemul de reconstrucție 3D.....	40
3.3.1	Etapele procesului de Reconstrucție 3D.....	40
3.3.2	Extragerea Caracteristicilor .....	42
3.3.3	Potrivirea caracteristicilor .....	48
3.3.4	Estimarea poziției camerei .....	49
3.3.5	Reconstrucția densă.....	51
3.3.5	Editarea modelului 3D .....	53
4.	Rezultate experimentale .....	55
4.1	Pregătirea obiectelor scanate .....	55
4.2	Calibrarea autofocusului și a luminiozității .....	55
4.3	Rezultatele reconstrucției 3D .....	56
5.	Concluzii .....	58
6.	Bibliografie.....	63
7.	Rezumat.....	71

Abstract.....	72
DECLARAȚIE PRIVIND ORIGINALITATEA .....	73

## 1.1 CONTEXTUL LUCRĂRII

În ultimii ani, scanarea 3D a devenit o tehnologie tot mai accesibilă și răspândită, cu aplicații în domenii variate precum ingineria, designul de produs, arheologia digitală. În paralel, comunitatea open-source a contribuit semnificativ la democratizarea accesului la echipamente și software de scanare 3D, oferind alternative ieftine, flexibile și personalizabile față de soluțiile comerciale.

Printre cele mai populare inițiative de acest tip se numără OpenScan, un sistem open-source de scanare 3D fotogrammetrică destinat obiectelor de mici dimensiuni. Acesta combină un cadru fizic imprimat 3D cu componente electronice simple, permițând captarea controlată a imaginilor pentru reconstrucția tridimensională a obiectelor.

Lucrarea de față are la bază dezvoltarea unui sistem propriu, care păstrează configurația hardware de bază, dar implementează o soluție de procesare independentă, bazată pe COLMAP – un software fotogrammetric academic recunoscut pentru performanța sa în reconstrucția 3D. Această abordare permite un control mai mare asupra etapelor de procesare, posibilitatea optimizării pipeline-ului și integrarea cu fluxuri de lucru personalizate.

Scopul lucrării este de a demonstra funcționalitatea acestui sistem adaptat, de a evalua calitatea rezultatelor obținute și de a evidenția avantajele și limitările utilizării unei soluții de procesare fotogrammetrică avansată într-un context low-cost și open-source.

## 1.2 STADIUL ACTUAL

În prezent, fotogrametria reprezintă o tehnologie matură, cu rol esențial în numeroase sectoare industriale. Evoluțiile din ultimii ani în domeniul camerelor digitale, al dronelor și al algoritmilor de procesare 3D au transformat fotogrametria dintr-un instrument dedicat exclusiv cartografiei într-o soluție versatilă, aplicabilă într-o varietate de contexte operaționale și comerciale.

Una dintre cele mai importante tendințe este integrarea fotogrametriei în procesele de automatizare industrială și digitalizare. Prin intermediul platformelor UAV (drone) și al software-urilor specializate (precum COLMAP, Agisoft Metashape, RealityCapture sau Pix4D), este posibilă

generarea rapidă a modelelor 3D, ortofotoplanurilor și norilor de puncte pentru analiză, măsurare și planificare.

În domeniul construcțiilor și ingineriei civile, fotogrametria este utilizată pentru documentarea șantierelor, verificarea execuției față de proiectele BIM, evaluarea volumelor de excavare sau terasamente, precum și pentru monitorizarea deformărilor structurale. În industrie și producție, metodele fotogrammetrice contribuie la controlul calității, inspecția dimensională și reconstrucția pieselor tehnice.

De asemenea, în sectoarele energetic și minier, fotogrametria oferă soluții eficiente pentru inspecții la distanță, reducând riscurile pentru personal și timpul de intervenție. Tot mai frecvent, aceasta este integrată cu tehnologii emergente precum inteligența artificială, realitatea augmentată și digital twin, susținând tranziția spre Industria 4.0.

Pe măsură ce tehnologia devine tot mai accesibilă, iar software-urile open-source (ca COLMAP sau Meshroom) oferă alternative competitive, fotogrametria continuă să câștige teren ca metodă de lucru standardizată în numeroase aplicații industriale, fiind apreciată pentru precizie, costuri reduse și flexibilitate.

### 1.3 OBIECTIVUL LUCRĂRII

Lucrarea prezintă dezvoltarea unui sistem propriu de scanare 3D, bazat pe tehnologia fotogrammetrică, cu focus pe implementarea unei soluții de procesare independente utilizând COLMAP. Obiectivul principal este demonstrarea funcționalității unui sistem adaptat care păstrează configurația hardware de bază, dar care implementează o soluție de procesare fotogrammetrică avansată într-un context low-cost și open-source. Sistemul își propune să realizeze scanări detaliate și reproductibile, beneficiind de un echilibru optim între precizia mecanică, calitatea optică și stabilitatea operațională.

Astfel, au fost elaborate următoarele obiective :

#### *01. Cercetarea literaturii de specialitate din tema aleasă*

*01.1. Analiza comparativă a tehnologiilor existente de scanare 3D (laser, lumină structurată, fotogrammetrie)*

*01.2. Identificarea avantajelor și limitărilor tehnologiilor de scanare 3D în contextul actual.*

*01.3. Studiarea tendințelor și integrării fotogrammetriei în procesele de automatizare industrială.*



## *02. Proiectarea și descrierea sistemului*

*02.1. Definirea arhitecturii hardware bazată pe componente accesibile (Raspberry Pi 4B, motoare pas cu pas, cameră de înaltă rezoluție)*

*02.2. Proiectarea sistemului mecanic cu focus pe precizie, stabilitate și reproductibilitate*

*02.3. Integrarea soluției software COLMAP pentru procesarea fotogrammetrică avansată*

## *03. Dezvoltarea software și hardware*

*03.1. Implementarea sistemului de control automatizat pentru achiziția de date*

*03.2. Dezvoltarea procesului de calibrare și optimizare a sistemului*

*03.3. Integrarea algoritmilor de procesare pentru reconstrucția 3D automată*

## *04. Testarea și evaluarea sistemului*

*04.1. Evaluarea preciziei și acurateții sistemului în scanarea obiectelor*

*04.2. Testarea reproductibilității și fidelității rezultatelor*

*04.3. Analiza comparativă a performanței sistemului cu soluțiile comerciale existente*

Motivația dezvoltării acestui sistem este ancorată în contextul actual al democratizării tehnologiei de scanare 3D. În ultimii ani, scanarea 3D a devenit tot mai accesibilă și răspândită, cu aplicații diverse în inginerie, design de produs și arheologie digital. Alegerea COLMAP ca software de procesare se bazează pe capacitatea sa de a realiza reconstrucții 3D automate precise, folosind algoritmi matematici avansați și optimizări hardware. Sistemul propus reprezintă o alternativă competitivă și flexibilă față de soluțiile comerciale, fiind apreciat pentru precizie, costuri reduse și adaptabilitate. Procesul integrat, de la achiziția de date până la reconstrucția 3D, este implementat într-o manieră automatizată și controlată, utilizând componente accesibile precum Raspberry Pi 4B, motoare pas cu pas și o cameră de înaltă rezoluție.

## 2. NOȚIUNI FUNDAMENTALE

---

Fotogrametria este o metodă de obținere a informațiilor despre formele, dimensiunile și poziția obiectelor din lumea reală, prin analiza imaginilor fotografice. Cu alte cuvinte, este arta și știința de a transforma fotografii în date măsurabile, capabile să redea spațiul în mod precis. Prin intermediul fotogrametriei se pot construi modele 3D, hărți digitale sau planuri detaliate, fără a fi nevoie de contact direct cu obiectele sau terenul analizat.

Primele utilizări ale fotogrametriei datează din secolul al XIX-lea, odată cu dezvoltarea fotografiei. Unul dintre pionierii domeniului a fost Albrecht Meydenbauer, care în 1867 a propus folosirea imaginilor pentru măsurători arhitecturale. La început, fotogrametria era folosită mai ales pentru realizarea hărților, pe baza fotografiilor obținute din baloane sau avioane. De-a lungul timpului, tehnologia s-a perfecționat, trecând de la metode optice și mecanice la sisteme digitale complet automatizate.

Scanarea 3D este o tehnologie care captează forma și aspectul obiectelor sau mediilor din lumea reală, transformându-le în modele digitale 3D precise. Este un proces noncontact, nedistructiv, care joacă un rol crucial în industriile moderne, în cercetare și în aplicațiile centrate pe om. Scanarea 3D permite replicarea digitală precisă, analiza și proiectarea, făcând-o fundamentală pentru Industria 4.0, producție, asistență medicală și multe altele.

Astăzi, fotogrametria digitală se bazează pe imagini captate cu camere foto performante – montate pe drone, avioane sau chiar telefoane mobile – și pe programe software care pot reconstrui automat suprafețele și obiectele fotografiate în 3D. Un proces des întâlnit este „Structure-from-Motion” (SfM), care permite identificarea punctelor comune din mai multe imagini și reconstruirea formei reale a obiectelor sau terenului, cu precizie milimetrică (Schönberger & Frahm, 2016). Aplicațiile moderne ale fotogrametriei sunt foarte diverse și depășesc cu mult sfera cartografiei. În arhitectură și urbanism, este folosită pentru modelarea clădirilor sau planificarea orașelor. În arheologie, permite documentarea siturilor istorice fără a le afecta. În agricultură, ajută la monitorizarea culturilor, iar în construcții și industrie, este folosită pentru verificarea dimensiunilor, urmărirea evoluției șantierelor sau inspecția structurilor. De asemenea, fotogrametria joacă un rol tot mai important în domeniul jocurilor video, realității virtuale și efectelor speciale, unde ajută la crearea unor medii digitale cât mai realiste.

Pe măsură ce tehnologia avansează, fotogrametria devine tot mai accesibilă, mai precisă și mai prezentă în viața noastră, fiind un exemplu excelent de îmbinare a viziunii științifice cu instrumente moderne și creative.

În ceea ce privește întrebarea „ Poate fotogrametria să reconstruiască cu acuratețe modele 3D din imagini? ” este evident că literatura de specialitate din domeniu susține acest fapt. În continuare vor fi dezvoltate argumentele care susțin scopul și contribuția pe care fotogrametria o servește obținerii de modele 3D.

Fotogrametria poate reconstrui cu acuratețe modele 3D din imagini, atingând adesea erori de măsurare mai mici de 2% și o precizie sub-milimetrică. Este o metodă fiabilă, rentabilă și accesibilă pentru crearea de modele 3D detaliate, deși precizia sa poate depinde de factori precum calitatea imaginii, suprafața obiectului și software-ul specific utilizat.

Fidelitatea reconstrucției fotogrammetrice a fost validată în detaliu prin studii cuprinzătoare care compară aceste modele cu standarde de referință stabilite, inclusiv microCT și măsurători directe. Cercetările au demonstrat în mod constant o precizie impresionantă, diferențele absolute medii încadrându-se de obicei între 0,2 mm și 0,4 mm. Pentru analizele metrice și morfometrice brute, erorile de măsurare rămân în general la sau sub 2%, stabilind fotogrametria ca o metodă de documentare extrem de precisă (Dindaroğlu et al., 2016; Aliotta, 2024; Feddema & Chiu, 2024; Waltenberger et al., 2021). Forța metodei este evidențiată în continuare de caracteristicile sale puternice de repetabilitate și de variația minimă între diferiți observatori și între mai multe observații ale aceluiași observator, ceea ce o face deosebit de valoroasă atât pentru analize cantitative, cât și pentru aplicații educaționale (Aliotta, 2024; Feddema & Chiu, 2024). Atunci când este comparată cu alte metode consacrate, cum ar fi CT și scanarea cu lumină structurată, fotogrametria produce modele de suprafață și variabile de formă de calitate comparabilă, cu abateri medii între metode care variază de obicei între 100 și 200 de micrometri (Waltenberger et al., 2021).

Calitatea reconstrucției fotogrammetrice este influențată semnificativ de mai mulți factori-cheie. Prelucrarea imaginilor joacă un rol crucial, studiile arătând că îmbunătățirile strategice, cum ar fi ajustarea contrastului și selectarea adecvată a hărților de culori, pot îmbunătăți substanțial potrivirea punctelor-cheie și precizia generală a reconstrucției. În medii dificile, aceste optimizări au condus la îmbunătățiri remarcabile ale preciziei, unele cazuri raportând îmbunătățiri de până la 64% (Tzovaras et al., 2025). Caracteristicile fizice ale subiectului au, de asemenea, un impact semnificativ asupra calității reconstrucției. Suprafețele lipsite de caracteristici distincte sau cele cu texturi monocrome pot reprezenta o provocare pentru o reconstrucție precisă. Cu toate acestea, aceste limitări pot fi abordate în mod eficient prin integrarea fotogrammetriei cu tehnici de imagistică complementare, cum ar fi stereometria fotometrică și imagistica prin transformare a reflectanței, permițând recuperarea detaliilor fine și

îmbunătățirea rezultatelor generale (Karami et al., 2022; Bilmes et al., 2024). Alegerea software-ului de fotogrammetrie reprezintă un alt factor critic, deoarece calitatea modelelor 3D poate varia considerabil între diferite pachete software. Această variație subliniază importanța validării aprofundate și a testelor pilot înainte de implementarea fotogrammetriei în aplicații critice (Zhang & Maga, 2023; Waltenberger et al., 2021).

Procesul fotogrametric constă din mai multe etape critice, fiecare contribuind la acuratețea și calitatea modelului final. Faza inițială, capturarea imaginilor, implică realizarea mai multor fotografii suprapuse din puncte de vedere atent planificate în jurul subiectului. Succesul acestei etape depinde în mare măsură de calitatea, claritatea și acoperirea cuprinzătoare a acestor imagini, abordările sistematice de fotografiere îmbunătățind semnificativ atât calitatea, cât și precizia modelului (T et al., 2024; Gárdonyi et al., 2023; Nagy et al., 2023; Izvozchikova et al., 2020). După captarea imaginilor, software-ul specializat efectuează estimarea poziției camerei, o etapă crucială care determină poziția și orientarea exactă a camerei pentru fiecare fotografie, permițând alinierea precisă a imaginilor în spațiul tridimensional (Zhang & Maga, 2023; T et al., 2024; Izvozchikova et al., 2020).

După captarea imaginilor, software-ul specializat efectuează estimarea poziției camerei, o etapă crucială care determină poziția și orientarea exactă a camerei pentru fiecare fotografie, permițând alinierea precisă a imaginilor în spațiul tridimensional (Zhang & Maga, 2023; T et al., 2024; Izvozchikova et al., 2020). Procesul trece apoi la generarea norului de puncte, în care software-ul identifică caracteristicile comune ale setului de imagini și calculează coordonatele lor tridimensionale, rezultând un „nor de puncte” dens care reprezintă cu precizie suprafața obiectului (Zhang & Maga, 2023; T et al., 2024; Izvozchikova et al., 2020). Etapa finală implică crearea de ochiuri și texturi, în care norul de puncte este transformat într-o plasă poligonală care formează suprafața obiectului. Această plasă este apoi îmbunătățită cu texturi realiste derivate din fotografiile originale, care sunt atent mapate pe suprafață pentru a obține un aspect fotorealistic (Zhang & Maga, 2023; T et al., 2024; Ryan, 2019; Krause et al., 2023).

### **Ce avantaje oferă fotogrametria față de metodele tradiționale?**

Avantajele economice și de accesibilitate ale fotogrammetriei sunt deosebit de notabile în peisajul digital actual. Din perspectiva costurilor, dependența tehnologiei de camerele foto standard sau de smartphone-uri reprezintă un avantaj financiar semnificativ în comparație cu investițiile substanțiale necesare pentru CT, RMN sau echipamentele de scanare laser (Cattrysse et al., 2024; Luchowski et al., 2021; Gröning et al., 2019; Bartoš et al., 2014). Această abordare

rentabilă, combinată cu disponibilitatea software-ului open-source, a democratizat accesul la capacitățile de modelare tridimensională, făcând-o deosebit de valoroasă în mediile cu resurse limitate (Cattrysse et al., 2024; Luchowski et al., 2021; Bartoš et al., 2014).

Aspectele operaționale ale fotogrammetriei demonstrează o eficiență și o adaptabilitate remarcabile. Metoda permite achiziționarea și prelucrarea rapidă a datelor, în special atunci când se utilizează soluții software automatizate sau ușor de utilizat (Skamantzari et al., 2023; Schroder et al., 2020). Cerințele sale minime în materie de hardware contrastează puternic cu metodele tradiționale care necesită adesea configurații complexe sau greoaie ale echipamentelor, permițând implementarea versatilă în diverse medii (Valența et al., 2012; Luchowski et al., 2021; Rainer et al., 2022).

În ceea ce privește calitatea rezultatelor, fotogrammetria demonstrează capacități excepționale. Atunci când este implementată cu protocoale adecvate, aceasta produce modele tridimensionale extrem de precise care rivalizează adesea cu cele generate prin metode mai costisitoare (Cattrysse et al., 2024; Luchowski et al., 2021; Rainer et al., 2022; Gröning et al., 2019). Natura fără contact a procesului este deosebit de valoroasă pentru conservarea specimenelor sau artefactelor sensibile (Rainer et al., 2022; Gröning et al., 2019). În plus, fotogrammetria excelează în capturarea texturilor și culorilor suprafețelor, ceea ce o face neprețuită pentru vizualizare și aplicații educaționale (Schroder et al., 2020).

Scalabilitatea fotogrammetriei reprezintă un alt avantaj semnificativ. Tehnologia demonstrează o versatilitate remarcabilă în gestionarea unui număr aproape nelimitat de puncte de măsurare, permițând modelarea detaliată atât a obiectelor microscopice, cât și a structurilor la scară largă (Valența et al., 2012; Schroder et al., 2020). Progresele recente în dezvoltarea de software au automatizat semnificativ procesul fotogrametric, reducând necesitatea intervenției experților și accelerând finalizarea fluxului de lucru (Skamantzari et al., 2023; Noardo et al., 2018).

### **Principalele limitări ale reconstrucției fotogrametrice**

Reconstrucția fotogrametrică, deși adoptată pe scară largă pentru modelarea tridimensională din date fotografice, se confruntă cu mai multe limitări semnificative care îi pot afecta acuratețea, fiabilitatea și aplicarea practică. Aceste provocări se manifestă în principal în trei domenii-cheie: considerații privind calitatea imaginii, limitări privind caracteristicile suprafeței și complexitatea prelucrării datelor.

Succesul reconstrucției fotogrametrice depinde în mare măsură de calitatea imaginilor de intrare, diverși factori tehnici și de mediu jucând un rol crucial. Condițiile slabe de iluminare,

rezoluția insuficientă a imaginii sau setările suboptimale ale camerei pot compromite semnificativ acuratețea reconstrucției, necesitând o atenție deosebită la protocoalele de achiziție a imaginilor și necesitând adesea tehnici sofisticate de îmbunătățire pentru a obține rezultate fiabile (Gröning et al., 2019; Grammatikopoulos et al., 2023). Calibrarea camerei reprezintă o altă provocare critică, în special atunci când se lucrează cu materiale de arhivă sau cu diverse surse de fotografii, deoarece calibrarea inexactă sau inconsecventă poate introduce erori substanțiale și poate diminua fidelitatea generală a modelului (Wallace, 2022).

Eficacitatea metodei este pusă la încercare în special de anumite caracteristici ale suprafețelor și proprietăți ale obiectelor. Suprafețele necooperante, inclusiv materialele fără textură, suprafețele metalice și obiectele transparente sau translucide, duc adesea la reconstrucții incomplete sau imprecise, necesitând frecvent integrarea unor tehnici alternative sau abordări metodologice combinate (Yan et al., 2023; Karami et al., 2022). În plus, obiectele cu geometrii complexe sau ocluzii semnificative necesită adesea abordări de reconstrucție segmentată, în care obiectul trebuie împărțit în secțiuni mai mici, ușor de gestionat, deși zonele ocluzive pot rămâne totuși incomplete sau necesită tehnici sofisticate de umplere (Ozimek et al., 2021).

Gestionarea și prelucrarea seturilor mari de date reprezintă provocări tehnice semnificative în reconstrucția fotogrammetrică. Procesarea automată a colecțiilor extinse de imagini întâmpină frecvent dificultăți în menținerea orientării corecte, asigurarea calității metrice și obținerea unei reproductibilități consecvente. Provocarea de a gestiona redundanța menținând în același timp consecvența rezultatelor în medii mari sau complexe necesită abordări computaționale sofisticate (Menna et al., 2017; Ozimek et al., 2021). În plus, utilizarea fotografiilor de arhivă sau a imaginilor din surse și perioade de timp variate introduce complexități suplimentare, în special atunci când lipsesc metadatele esențiale sau calitatea imaginii variază semnificativ în cadrul setului de date (Wallace, 2022).

### **Principiile fundamentale ale scanării cu laser și cu lumină structurată**

Scanarea cu laser și scanarea cu lumină structurată reprezintă abordări sofisticate ale captării datelor tridimensionale, fiecare utilizând principii distincte de proiecție și analiză a luminii pentru a obține măsurători de înaltă rezoluție. Deși ambele metode vizează crearea de reprezentări spațiale detaliate, mecanismele și aplicațiile care stau la baza lor diferă semnificativ.

Tehnologia de scanare cu laser funcționează pe principiul fundamental al măsurării distanței prin reflexia luminii. Procesul implică emiterea sistematică de raze laser focalizate și măsurarea precisă a reflexiilor acestora, fie prin calcularea timpului de zbor, fie prin analiza

defazajului. Se creează astfel o reprezentare completă a suprafeței scanate sub formă de nor de puncte (Briese & Pfeifer, 2007; Scholes et al., 2020). Tehnologia utilizează mai multe metodologii sofisticate de măsurare a distanței, inclusiv măsurători ale impulsurilor temporizate care calculează durata revenirii impulsurilor laser, tehnici de comparare a fazelor care analizează deplasările dintre semnalele emise și recepționate și metoda heterodină, care utilizează deplasările de frecvență (Petrie & Toth, 2017). Acoperirea prin scanare sistematică se realizează prin diverse mecanisme de deviere, inclusiv oglinzi de precizie, dispozitive MEMS sau platforme rotative care direcționează fasciculul laser în zona țintă (Briese & Pfeifer, 2007; Scholes et al., 2020; Zhang et al., 2024). Această versatilitate permite aplicații de scanare cu laser la scări multiple, de la platforme aeriene și terestre la platforme de satelit, servind unor scopuri diverse, inclusiv cartografierea, inspecția infrastructurii și diverse alte aplicații (Briese & Pfeifer, 2007; Scholes et al., 2020).

Scanarea cu lumină structurată utilizează o abordare diferită, proiectând modele predeterminate precum dungi, puncte sau grile pe suprafețele obiectelor. Aceste modele sunt captate de camere specializate, iar software-ul sofisticat analizează deformarea lor pentru a reconstrui forme tridimensionale (Wang & Liu, 2021; Khan et al., 2023; Scholes et al., 2020; Zhang et al., 2024). Generarea acestor modele implică tehnici optice avansate, utilizând lasere cu caracteristici de amplitudine, fază și polarizare controlate cu precizie sau folosind oglinzi MEMS pentru crearea dinamică a modelelor (Uesugi et al., 2023; Forbes, 2018; Zhang et al., 2024). Sistemul atinge o precizie ridicată prin triangulare, calculând poziția fiecărui element al modelului pentru a determina geometria suprafeței, ceea ce îl face deosebit de eficient pentru captarea caracteristicilor detaliate ale obiectelor mici (Wang & Liu, 2021; Khan et al., 2023; Scholes et al., 2020; Zhang et al., 2024).

### **Cum se compară diferitele metode de scanare 3D în ceea ce privește performanța?**

Performanțele metodelor de scanare 3D prezintă variații semnificative în funcție de tehnologia utilizată, de obiectul țintă și de aplicația preconizată. În aplicațiile de scanare dentară și facială, cercetările au arătat că scanerile intraorale care utilizează tehnologia confocală demonstrează o acuratețe superioară atât în ceea ce privește veridicitatea, cât și precizia, deși aceste sisteme necesită adesea durate de scanare mai lungi comparativ cu omologii lor bazați pe triangulație, care oferă rezultate mai rapide, dar mai puțin precise (Alharbi & Osman, 2022; Camps et al., 2018). În ceea ce privește scanarea feței și a mâinii, atât sistemele cu lumină structurată, cât și cele de stereofotogrammetrie se dovedesc eficiente, sistemele cu lumină structurată

oferind avantaje în ceea ce privește viteza de achiziție, menținând în același timp o precizie comparabilă cu metodele bazate pe CT, deși anumite scanere pot prezenta variații notabile de măsurare în anumite regiuni faciale (Scisciola et al., 2023; Antonaya-Martín et al., 2023; Yu et al., 2020).

Evoluțiile recente în domeniul tehnologiei mobile au dat rezultate promițătoare, aplicațiile moderne pentru smartphone-uri care utilizează captarea imaginilor în rotație completă atingând niveluri de fiabilitate comparabile cu scanerile 3D tradiționale, mai scumpe, deși aplicațiile mai simple cu două imagini, deși mai puțin precise, se pot dovedi adecvate pentru anumite aplicații (Tinoco et al., 2024). În domeniul fabricării de orteze, în timp ce scanarea 3D oferă, în general, o viteză îmbunătățită comparativ cu metodele tradiționale de turnare în ghips, precizia și fiabilitatea pot varia semnificativ în funcție de scannerul specific și de caracteristicile anatomice măsurate (Wang et al., 2021).

Atunci când se evaluează metodologii mai largi de reconstrucție 3D, scanarea cu laser oferă de obicei o precizie marginal superioară, deși la costuri și complexitate operațională mai mari. În schimb, fotogrammetria bazată pe imagini oferă o mai mare flexibilitate, rentabilitate și ușurință de utilizare, ceea ce o face o opțiune viabilă pentru aplicațiile în care precizia finală nu este esențială (Fan et al., 2021; Allegue et al., 2021). Cercetările demonstrează în mod constant că nicio metodă de scanare 3D nu reprezintă o soluție universală; alegerea optimă depinde de găsirea echilibrului corect între cerințele de precizie, viteza de procesare, constrângerile de cost și ușurința de utilizare (Alharbi & Osman, 2022; Fan et al., 2021; Allegue et al., 2021).

### **Principalele dezavantaje ale tehnologiilor de scanare 3D**

Implementarea tehnologiilor de scanare 3D se confruntă cu mai multe provocări semnificative, inclusiv costuri substanțiale de echipamente și operaționale, cerințe complexe de prelucrare a datelor și limitări inerente în scanarea anumitor materiale sau suprafețe. O limitare tehnică notabilă este dificultatea de a scana cu precizie obiecte lucioase, reflectorizante sau transparente, ceea ce duce adesea la modele digitale incomplete sau inexacte (Abdel-Bary, 2015; Onyia et al., 2025). Procesul de scanare produce frecvent date cu imperfecțiuni, cum ar fi zgomot și găuri în informațiile de suprafață capturate, necesitând algoritmi sofisticati pentru postprocesare și reconstrucția precisă a suprafeței (Onyia et al., 2025; Helle & Lemu, 2021).

În aplicațiile medicale, utilitatea tehnologiei este constrânsă de limitarea sa la captarea suprafețelor externe, neputând furniza informații despre structurile interne, ceea ce limitează aplicațiile sale în comparație cu modalitățile de imagistică cuprinzătoare precum CT sau RMN



(Haleem & Javaid, 2018). O altă provocare semnificativă constă în gestionarea și prelucrarea eficientă a volumelor substanțiale de date generate de scanările de înaltă rezoluție, care necesită resurse computaționale considerabile (Onyia et al., 2025). Deși aplicațiile de scanare 3D bazate pe telefoane mobile au îmbunătățit accesibilitatea, acestea prezintă de obicei erori de măsurare mai mari comparativ cu sistemele tradiționale, mai costisitoare, în special atunci când este vorba de măsurători detaliate sau segmentare (Tinoco et al., 2024).

În ciuda acestor provocări, scanarea 3D continuă să ofere beneficii substanțiale în diverse domenii, inclusiv inginerie, asistență medicală și design de produse. Cu toate acestea, abordarea acestor limitări rămâne esențială pentru realizarea deplină a potențialului tehnologiei (Onyia et al., 2025; Helle & Lemu, 2021; Balasubramanian & Sheykholeki, 2025; Haleem & Javaid, 2018).

### **Avantajele abordărilor hibride de reconstrucție**

Abordările hibride de reconstrucție oferă beneficii semnificative prin combinarea punctelor forte ale mai multor tehnici sau surse de date pentru a îmbunătăți precizia, eficiența și rezultatele clinice. În imagistica medicală, reconstrucția CT spectrală hibridă îmbină rezoluția spațială ridicată și zgomotul redus ale detectoarelor cu integrare de energie cu capacitățile spectrale ale detectoarelor de numărare a fotonilor, rezultând o separare îmbunătățită a materialelor, o rezoluție spațială îmbunătățită și o detectabilitate a contrastelor scăzute de până la 2,6 ori mai bună comparativ cu metodele cu o singură modalitate (Clark & Badea, 2017).

În aplicațiile chirurgicale, cum ar fi reconstrucția mamară hibridă prepectorală, combinarea țesutului autolog cu implanturile oferă o formă și o proiecție naturală a sânilor, reducând în același timp complicațiile precum ondulația sau deformarea animației și menținând un profil de siguranță favorabil (Kanchwala & Momeni, 2018). Pentru chirurgia coloanei vertebrale, tehnicile hibride de decompresie și reconstrucție echilibrează beneficiile corpectomiei și ale discectomiei, ducând la o mai bună aliniere a coloanei vertebrale, rate mai mari de fuziune și mai puține complicații decât abordările tradiționale (Deutsch et al., 2020).

În repararea peretelui abdominal, metodele hibride care integrează tehnici minim invazive și deschise pot scurta șederea în spital, pot reduce costurile și pot reduce ratele complicațiilor fără a crește timpul operator (Belyansky et al., 2020). În domeniile de calcul, schemele hibridizate de reconstrucție a fluxului îmbunătățesc eficiența de calcul, precizia și viteza de convergență pentru sarcinile de reconstrucție a imaginilor și datelor (Pereira & Vermeire, 2022). În general, abordările hibride de reconstrucție valorifică avantajele complementare pentru a obține rezultate

superioare atât în domeniul clinic, cât și în cel tehnic (Clark & Badea, 2017; Kanchwala & Momeni, 2018; Pereira & Vermeire, 2022; Deutsch et al., 2020; Belyansky et al., 2020).

### **Cum transformă reconstrucția 3D aplicațiile industriale?**

Reconstrucția 3D transformă în mod semnificativ aplicațiile industriale, permițând modelarea precisă, eficientă și automată a obiectelor și a mediilor, ceea ce este esențial pentru sectoare precum producția, planificarea urbană și construcțiile. Tehnicile avansate, inclusiv învățarea profundă și scanarea cu lumină structurată, permit acum măsurători de suprafață de mare viteză, fără contact și extrem de precise, îmbunătățind controlul calității și metrologia dimensională în procesele de fabricație (G & R, 2025; Dold et al., 2022).

Integrarea metodelor bazate pe inteligența artificială, cum ar fi câmpurile neuronale de radianță și învățarea nesupravegheată, facilitează crearea de gemeni digitali - replici virtuale ale activelor fizice - fără a fi nevoie de un număr mare de date etichetate, accelerând astfel adoptarea practicilor industriei 4.0 (Walton et al., 2025). Aceste gemene digitale îmbunătățesc întreținerea predictivă, optimizarea proceselor și monitorizarea în timp real. Conducele de reconstrucție 3D automatizate și robuste reduc, de asemenea, intervenția manuală și acumularea de erori, făcând posibilă modelarea la scară largă și de înaltă fidelitate pentru medii industriale complexe (Walton et al., 2025).

În plus, metodele de reconstrucție 3D cu o singură imagine și în timp real simplifică inspecțiile și operațiunile robotizate, permițând adaptarea rapidă la scenariile industriale dinamice (Dold et al., 2022). Evoluția continuă a metodelor de reconstrucție 3D, în special a celor care valorifică învățarea profundă, determină o scalabilitate, o adaptabilitate și o integrare mai mari în fluxurile de lucru industriale existente, ceea ce conduce în cele din urmă la sisteme industriale mai inteligente, mai eficiente și mai flexibile (Walton et al., 2025).

### **Evoluția metodelor de reconstrucție**

Metodele de reconstrucție 3D evoluează rapid, datorită progreselor în învățarea profundă, creșterii puterii de calcul și noilor abordări algoritmice. Tehnicile tradiționale, cum ar fi triangulația laser, stereoscopia și fotogrammetria, au fost fundamentale, dar în ultimii ani s-a înregistrat o schimbare către metodele bazate pe învățarea profundă, care pot reconstrui forme 3D din imagini unice sau multiple, cu o mai mare flexibilitate și mai puțină dependență de hardware specializat sau calibrare precisă (B et al., 2019; Zhou et al., 2024; Samavati & Soryani, 2023).

În special, câmpurile neuronale de radianță (NeRF) și algoritmi aferenți au permis reconstrucții de înaltă fidelitate chiar și în scene complexe, îmbunătățind semnificativ atât precizia, cât și eficiența (Zhou et al., 2024). Aceste metode utilizează rețele neuronale convoluționale, autoencodere și rețele generative adversariale pentru a învăța caracteristici semantice direct din date, reducând intervenția manuală și erorile cumulative (B et al., 2019; Samavati & Soryani, 2023). Aplicațiile se extind acum de la robotică și realitate virtuală la medicină și inginerie civilă la scară largă, cu un accent tot mai mare pe modelarea în timp real, fuziunea datelor și fluxurile de lucru automate (Lu et al., 2024).

În ciuda acestor progrese, rămân provocări în ceea ce privește gestionarea scenelor dinamice, scalarea la medii mari și asigurarea robusteții la diferite calități ale imaginii și puncte de vedere (Zhou et al., 2024; Samavati & Soryani, 2023). Tendințele viitoare indică o mai mare integrare a învățării profunde, o generalizare îmbunătățită a modelului și o adaptabilitate sporită la medii diverse, promițând o adoptare și un impact și mai larg (B et al., 2019; Zhou et al., 2024).

### **Aplicații noi ale scanării și reconstrucției 3D apar în diferite domenii**

Noile aplicații ale scanării și reconstrucției 3D apar rapid în diverse domenii, datorită progreselor în viziunea computerizată, învățarea profundă și tehnologia senzorilor. În medicină și patologie, imagistica 3D transformă diagnosticarea și cercetarea, permițând reconstrucția histopatologică automatizată de mare capacitate și chiar imagistica ultrarapidă a proceselor biologice dinamice, cum ar fi activitatea neuronală, la viteze și rezoluții fără precedent (Jutt et al., 2017).

În industrie și inginerie, scanarea 3D este esențială pentru Industria 4.0, susținând ingineria inversă, controlul calității și modelarea precisă a componentelor complexe, facilitând, de asemenea, măsurarea fără contact în medii dificile (Kumar et al., 2022; Hu et al., 2021; Tao et al., 2021). Arhitectura și construcțiile beneficiază de modelarea 3D automatizată și scalabilă a mediilor interioare, care ajută la realitatea virtuală, navigație și simulare, precum și la generarea de planuri detaliate și modele fotorealiste (Turner et al., 2015).

În crearea de conținut digital, divertisment și educație, sistemele bazate pe inteligența artificială automatizează în prezent generarea de modele 3D de înaltă rezoluție din simple fotografii 2D, făcând accesibilă modelarea 3D avansată pentru animație, AR/VR și jocuri (Sneha, 2025; Zhou et al., 2024). În plus, noi algoritmi și tehnici de scanare îmbunătățesc fidelitatea, viteza și automatizarea reconstrucției 3D, reducând intervenția manuală și acumularea de erori și permițând aplicații în timp real sau aproape în timp real în producție, arheologie și nu numai

(Wang et al., 2024; Zhou et al., 2024). Aceste inovații extind domeniul de aplicare al scanării și reconstrucției 3D, făcându-le instrumente indispensabile atât în cercetarea științifică, cât și în aplicațiile practice din numeroase sectoare (Ioannidis & Verykokou, 2023; Kumar et al., 2022; Zhou et al., 2024).

### **Principalele lecții învățate din metodele actuale de reconstrucție 3D**

Metodele actuale de reconstrucție 3D, în special cele care valorifică învățarea profundă, au avansat semnificativ în domeniu, permițând inferența de la un capăt la altul a formelor 3D din imagini unice sau multiple, reducând dependența de conductele tradiționale în mai multe etape și de ingineria manuală a caracteristicilor (Samavati & Soryani, 2023; Pasini et al., 2024; B et al., 2019). Abordările de învățare profundă au îmbunătățit generalizarea și adaptabilitatea, permițând reconstrucția din date limitate sau chiar dintr-o singură vedere, și au extins aplicațiile în robotică, realitate virtuală, imagistică medicală și inginerie civilă (Samavati & Soryani, 2023; Lu et al., 2024).

Lecțiile cheie includ importanța alegerii reprezentărilor de ieșire adecvate (cum ar fi voxeli, nori de puncte, ochiuri sau suprafețe implicite), deoarece fiecare are compromisuri în ceea ce privește precizia, eficiența și adecvarea pentru diferite sarcini (Pasini et al., 2024; B et al., 2019). Integrarea informațiilor multi-view și valorificarea indicilor de umbră, poziție și iluminare pot îmbunătăți în continuare calitatea reconstrucției, în special pentru obiectele complexe sau concave (Samavati & Soryani, 2023; Pasini et al., 2024).

În ciuda acestor progrese, rămân provocări, inclusiv gestionarea scenelor dinamice, obținerea de performanțe în timp real și îmbunătățirea rezistenței la ocluzii și medii variabile (Lu et al., 2024). De asemenea, există o nevoie tot mai mare de repere standardizate, de tehnici mai bune de fuziune a datelor și de conducte de modelare mai automatizate și scalabile (Lu et al., 2024). Cercetările viitoare se vor concentra probabil pe optimizarea performanței, fuzionarea surselor de date eterogene și dezvoltarea de metode care necesită mai puțină supraveghere, menținând în același timp o fidelitate și o eficiență ridicate (Samavati & Soryani, 2023; Lu et al., 2024).

### 3.1 PREZENTARE GENERALĂ

Sistemul de scanare 3D dezvoltat este inspirat din designul OpenScan Mini, însă prezintă modificări semnificative pentru îmbunătățirea performanței și automatizării. Arhitectura hardware se bazează pe o platformă Raspberry Pi 4B, integrând senzori de calibrare adiționali și un sistem personalizat de achiziție și transfer de date. Controlul sistemului este realizat prin intermediul unei interfețe web dezvoltate cu framework-ul Flask, care permite ajustarea parametrilor esențiali precum focusul camerei, intensitatea LED-urilor și unghiul de incrementare al motoarelor stepper. Procesul de achiziție a datelor este complet automatizat, fiind implementat local pe Raspberry Pi, care gestionează atât componentele de acționare, cât și camera de înaltă rezoluție. Spre deosebire de sistemul original, reconstrucția 3D este executată pe PC utilizând software-ul COLMAP, care permite procesarea avansată a imaginilor și generarea modelelor 3D precise, cu erori maxime de doar 1-2mm în condiții optime. Această abordare oferă un control mai mare asupra etapelor de procesare și posibilitatea optimizării pipeline-ului conform cerințelor specifice.

### 3.2 SISTEM DE ACHIZIȚIE

#### 3.2.1 Design Hardware

În cadrul sistemului de scanare tridimensională, precizia și stabilitatea mișcărilor mecanice reprezintă factori esențiali pentru obținerea unor rezultate de înaltă calitate. Mișcarea controlată de rotație a camerei și a sursei de iluminare este realizată prin intermediul unui angrenaj compus dintr-o roată soare și o roată inelară. Această soluție mecanică permite transformarea rotației motorului pas cu pas într-o mișcare limitată și precisă a suportului camerei, asigurând poziționarea optimă necesară pentru captarea fidelă a detaliilor obiectului scanat. Masa rotativă reprezintă componenta esențială care susține și rotește obiectul scanat în timpul procesului de scanare tridimensională. Aceasta este direct conectată prin presare pe arborele motorului pas cu pas.

Axa de rotație a rotorului este definită ca axa **Z**, iar axa de rotație a mesei rotative este axa **X**. Astfel, mișcarea de rotație a camerei și a inelului de lumină se realizează în jurul axei **Z**, în timp ce obiectul scanat este rotit în jurul axei **X**. Această convenție de axe permite o descriere clară și un control precis al mișcărilor în sistemul de scanare tridimensională.

Angrenajul format din roata soare și roata inelară este ales pentru simplitatea sa constructivă și pentru capacitatea de a oferi un raport de transmisie ridicat într-un spațiu compact. Roata inelară, cu dinți pe interior, acoperă un arc de cerc limitat, iar roata soare, montată pe axul motorului, antrenează această roată, generând o rotație controlată a camerei pe un unghi prestabilit.

Pentru a asigura o funcționare corectă și durabilă a angrenajului, este necesară o proiectare atentă, care să țină cont de numărul de dinți, diametrele de divizare și modulul comun al celor două roți. Modulul determină dimensiunea dinților și influențează atât precizia angrenajului, cât și rezistența mecanică a acestuia.

În continuare, sunt prezentate specificațiile tehnice ale angrenajului utilizat în dispozitivul de scanare, urmate de calculele detaliate care stau la baza dimensionării corecte a componentelor.

### Specificații tehnice

**Roata inelară:** diametru exterior de 200mm și diametru de divizare 195mm, 126 dinți pe întreaga circumferință de 360° iar pe sectorul de cerc de 120° sunt 42 de dinți

**Roata soare:** 9 dinți, diametru exterior de 17.03mm și diametru de divizare 13.95mm

**Unghiul de rotație al roții inelare utilizat:** 120°

**Materiale:** componentele mecanice sunt realizate prin imprimare 3D din polilactidă, cunoscut ca PLA, cu lubrifiere pe bază de vaselină siliconică pentru reducerea frecării.

Modulul angrenajului reprezintă raportul dintre diametrul de divizare al roții dințate și numărul de dinți ai acesteia și se exprimă în milimetri.

Formula de calcul este:

$$m = \frac{d}{z}$$

unde:

- m este modulul angrenajului,
- d este diametrul de divizare,
- z este numărul de dinți.

Diametrul de divizare este un cerc imaginar pe care sunt poziționați dinții și reprezintă referința pentru calculul dimensiunilor angrenajului

Pentru angrenajul nostru, modulul este:

$$m = \frac{195}{126} = 1.55\text{mm}$$

Numărul de dinți pe arc de  $120^\circ$  al roții inelare este:

$$Z_{arc} = Z_{inelara} * \frac{120}{360} = 126 * \frac{1}{3} = 42$$

unde:

- $Z_{arc}$  este numarul de dinti pe arc,
- $Z_{inelara}$  este numarul total de dinti pe inel,

Raportul de transmisie pe arc este:

$$i = \frac{Z_{arc}}{Z_{roata\_soare}} = \frac{42}{9} = 4.66$$

unde:

- $i$  este raportul de transmisie,
- $Z_{roata\_soare}$  este numarul de dinti al rotii soare.

Numărul de rotații ale roții soare necesare pentru a roti roata inelară cu  $120^\circ$  este:

$$N = \frac{Z_{arc}}{Z_{roata\_soare}}$$

unde:

- $N$  este numarul de rotatii.

Astfel, roata soare trebuie să efectueze aproximativ 4,67 rotații complete pentru ca roata inelară să se rotească cu  $120^\circ$  de grade.

Unghiul de rotație al roții inelare corespunzător unei rotații complete a roții soare este:

$$\alpha = 360^\circ * \frac{Z_{roata\_soare}}{Z_{inelara}}$$

Aceasta înseamnă că pentru fiecare rotație completă a roții soare, roata inelară se rotește cu aproximativ  $25,7^\circ$ .

Configurarea angrenajului cu roata inelară de 200 mm diametru exterior și 126 dinți, împreună cu roata soare de 9 dinți și diametru exterior aproximativ 17 mm, asigură un modul comun de aproximativ 1.55 mm, garantând o angrenare corectă și eficientă. Pentru a roti roata inelară cu  $120^\circ$  de grade, roata soare trebuie să efectueze aproximativ 4,67 rotații complete, iar pentru fiecare rotație completă a roții soare, roata inelară se rotește cu  $25,7^\circ$  de grade.

Această configurație este optimă pentru sistemul de scanare tridimensională, asigurând precizie în poziționarea camerei și a inelului de lumină, precum și o funcționare fiabilă și durabilă a ansamblului mecanic.

Motoarele pas cu pas sunt fixate ferm pe structura de bază a dispozitivului cu ajutorul șuruburilor cu filet metric M3. Această soluție asigură o prindere rigidă, necesară pentru

transmiterea precisă a mișcării către roata soare și, implicit, către roata inelară. Structura de bază, realizată prin imprimare 3D din polilactidă, este asamblată și ea cu șuruburi M3, care conferă rigiditate ansamblului și permit demontarea facilă în caz de necesitate.

Camera și inelul de iluminare formează un ansamblu integrat, fixat pe rotor prin șuruburi din nylon. Acestea asigură o prindere fermă, dar permit și o demontare ușoară pentru calibrare sau întreținere. Inelul de iluminare este montat pe rotor cu șuruburi M3, garantând poziționarea stabilă în timpul rotației. În total, ansamblul utilizează douăzeci de șuruburi M3 pentru fixarea tuturor componentelor esențiale, inclusiv motoare, suporturi, rotor și inelul de iluminare.



Figură 1. Ansamblul Sistemului de achiziție



Figură 2. Secțiune angrenaj

### 3.2.2 Componente utilizate

#### 3.2.2.1 Raspberry Pi 4 Model B

Sistemul este construit în jurul platformei Raspberry Pi 4 Model B cu 4 GB RAM, care servește drept centru de comandă și control. Această unitate centrală este responsabilă pentru orchestrarea tuturor operațiunilor esențiale, de la controlul motoarelor pas cu pas până la managementul imaginilor și comunicarea cu stația de procesare. Selecția acestei platforme a fost motivată de performanța sa computațională superioară, versatilitatea conexiunilor și adaptabilitatea în dezvoltarea software, oferind astfel un ecosistem complet pentru implementarea funcțiilor de control și achiziție.

Configurația software a sistemului începe cu instalarea Raspberry Pi OS 64-bit pe un card microSD de 64 GB, proces realizat cu ajutorul Raspberry Pi Imager. Procesul de setup începe cu o conexiune Wi-Fi temporară pentru configurarea inițială, urmată de identificarea adresei IP și stabilirea accesului SSH pentru administrare la distanță. Mediul de dezvoltare include Python 3.11, esențial pentru aplicațiile personalizate ale proiectului, creând astfel o bază robustă pentru integrarea tuturor componentelor sistemului. Din punct de vedere al consumului energetic, sistemul prezintă un consum de 1.3A în timpul operării active și 1A în stare de repaus. Integrarea



hardware se realizează prin intermediul pinilor GPIO ai plăcii Raspberry Pi 4 Model B, fiecare fiind alocat strategic pentru funcții specifice de control și achiziție. Această arhitectură permite o comunicare directă și eficientă între componentele software și cele hardware, asigurând coordonarea precisă a mișcărilor și procesului de captură. Distribuția și rolul specific al fiecărui pin sunt documentate detaliat în tabelul de configurare, care specifică atât semnalul asociat, cât și natura sa funcțională.

Tabelul următor descrie rolul fiecărui pin utilizat în proiect, specificând semnalul asociat și tipul acestuia:

*Tabel 1. Alocarea pinilor GPIO în cadrul Raspberry Pi*

Nr. PIN	Descriere Semnal	Tip Semnal
5	Directie Rotor	Digital Output
6	Pas Rotor	Digital Output
23	Enable Rotor	Digital Output
9	Directie Masa rotativa	Digital Output
11	Pas Masa rotativa	Digital Output
22	Enable Masa rotativa	Digital Output
24	Senzor Capat	Digital Input
17	Ringlight LED	Analog Output

Structura hardware implementată facilitează următoarele funcționalități cheie:

- Operarea precisă a ansamblului de motoare pas cu pas, atât pentru componenta de rotație, cât și pentru platforma rotativă, prin intermediul unui set dedicat de semnale digitale (direcție, pas și enable), rezultând într-o sincronizare optimă a mișcărilor;
- Monitorizarea poziționării rotorului prin implementarea unui sistem de detecție bazat pe senzor de capăt de cursă cu configurație normal deschisă (NO), oferind un punct de referință mecanic esențial pentru calibrare;
- Managementul sistemului de iluminare prin controlul LED-ului circular (Ringlight) utilizând semnal analogic modulat, permițând ajustarea fină a nivelului de luminozitate în funcție de necesitățile scanării;
- Integrarea completă a tuturor acestor funcții prin intermediul pinilor GPIO, gestionați de aplicația software rezidentă pe Raspberry Pi, asigurând astfel o sinergie perfectă între

componentele mecanice și sistemul de procesare, cu accent pe stabilitate și acuratețe în operare.

### ***3.2.2.2 Motor pas cu pas***

Sistemul de acționare mecanică este bazat pe implementarea motoarelor pas cu pas NEMA 17, selectate strategic pentru controlul precis al mișcărilor atât ale platformei rotative, cât și ale ansamblului vertical. Aceste unități de acționare excelează prin capacitatea lor de a executa mișcări incrementale cu înaltă precizie și repetabilitate, caracteristici fundamentale pentru procesul de digitalizare tridimensională. Motoarele NEMA 17 se remarcă prin generarea unui cuplu optim pentru cerințele mecanice ale sistemului și printr-o integrare naturală cu circuitele de comandă electronice utilizate. Din perspectiva consumului energetic, acestea operează la un curent nominal de 1.2A, reprezentând un compromis eficient între performanță și eficiență energetică.

### ***3.2.2.3 Driver de motor pas cu pas A4988***

Sistemul de comandă al motoarelor pas cu pas este implementat prin intermediul controlerelor A4988, module specializate care oferă un control granular asupra parametrilor de funcționare. Aceste drivere specializate permit atât ajustarea precisă a curentului, cât și configurarea modului de operare al motoarelor, incluzând funcția avansată de microstepping pentru optimizarea fluidității mișcării și îmbunătățirea rezoluției. Arhitectura A4988 încorporează mecanisme de protecție împotriva supracurentului și supraîncălzirii, garantând astfel o operare robustă și sigură în diverse scenarii de utilizare. Din punct de vedere energetic, modulele prezintă un consum modest de doar 0.02A.

Un aspect crucial în configurarea sistemului îl reprezintă calibrarea curentului maxim furnizat către motoare, proces realizat prin ajustarea tensiunii de referință ( $V_{ref}$ ) disponibilă pe potențiometrul integrat al driverului A4988. Această tensiune de referință este direct corelată cu limita de curent pe fază conform unei formule specifice de calcul:

$$I_{max} = \frac{V_{Ref}}{8 * R_s}$$

unde:

- $I_{max}/I_{max}$  este curentul maxim pe fază (în amperi),
- $V_{ref}/V_{ref}$  este tensiunea de referință măsurată pe trimer (în volți),
- $R_s/R_s$  este rezistența de detecție a curentului (în ohmi).

În cazul sistemului nostru, tensiunea de alimentare este de 12 V, iar rezistența de detecție utilizată este  $R_s=0.1 \Omega$ .

Pentru a stabili tensiunea  $V_{ref}$  necesară pentru un curent maxim dorit  $I_{max}$ , formula se poate rescrie:

$$V_{ref} = I_{max} * 8 * R_s$$

Pentru motoarele pas cu pas NEMA 17 utilizate în sistem, curentul maxim recomandat este în general în jur de 1.2 A până la 1.5 A.

Pentru valoarea minima calculul este:

$$V_{ref} = 1.2 * 8 * 0.1 = 0.96 V$$

Pentru valoarea maxima calculul este:

$$V_{ref} = 1.5 * 8 * 0.1 = 1.2 V$$

Astfel, pentru a proteja motorul și driverul, se recomandă reglarea potențiometrului driverului A4988 astfel încât să se atingă o tensiune de referință între 0.96 V și 1.2 V, în cazul de fata tensiunea de referinta este setata la 1.1 V.

#### **3.2.2.4 Cameră Arducam IMX519**

Componenta de captură imagistică este implementată utilizând modulul Arducam IMX519, un sistem performant dotat cu senzor de 16 megapixeli ( $4656 \times 3496$ ). Integrarea cu unitatea centrală Raspberry Pi este realizată prin intermediul interfeței CSI (Camera Serial Interface) de tip MIPI CSI-2, asigurând o transmisie eficientă și rapidă a datelor. Arhitectura modulului permite controlul programatic al parametrilor esențiali, incluzând expunerea, focalizarea și temporizarea capturii, facilitând astfel optimizarea condițiilor de achiziție pentru diverse scenarii de scanare. Un avantaj notabil al acestui modul este capacitatea sa de a focaliza la o distanță minimă de 5 mm, caracteristică ce permite capturarea cu fidelitate a detaliilor microscopice. Consumul energetic al modulului se situează la 0.1A.

Procesul de integrare a modulului Arducam IMX519 cu platforma Raspberry Pi 4 Model B necesită o configurare software specifică pentru asigurarea compatibilității și performanței optime. Acest proces începe cu actualizarea completă a sistemului de operare Raspberry Pi OS, inclusiv kernel-ul, pentru a asigura suportul necesar modulului de cameră.

Configurarea sistemului implică modificarea fișierului bootloader (/boot/firmware/config.txt) prin adăugarea directivei `dtoverlay=imx519`, esențială pentru recunoașterea și inițializarea corectă a senzorului la pornirea sistemului. Implementarea necesită o repornire a sistemului pentru activarea modificărilor.

Funcționalitatea completă este asigurată prin instalarea pachetelor software specifice Arducam, care includ bibliotecile libcamera și utilitarele necesare pentru controlul și achiziția imaginilor. Această suită software permite accesul la funcționalitățile avansate ale senzorului și ajustarea fină a parametrilor de captură.

#### ***3.2.2.5 Iluminare LED tip Ring Light***

Sistemul de iluminare este implementat printr-o configurație circulară specializată, constând într-un inel LED cu 9 puncte de lumină distribuite strategic pe circumferință. Designul integrează camera în centrul geometric al inelului luminos, rezultând într-o distribuție optimă a luminii pe suprafața obiectului scanat. Această arhitectură de iluminare a fost concepută pentru a minimiza formarea umbrelor pronunțate și a elimina reflexiile parazite, contribuind astfel la îmbunătățirea calității imaginilor achiziționate și, implicit, la creșterea preciziei în procesul de reconstrucție fotogrammetrică. Din perspectiva consumului energetic, ansamblul de iluminare operează la un curent nominal de 0.2A.

#### ***3.2.2.6 Senzor de capăt Rotor***

Sistemul de referință mecanică este implementat prin intermediul unui senzor de capăt de cursă, element esențial pentru calibrarea poziției inițiale și stabilirea unui punct zero precis al sistemului de acționare. Această soluție tehnică asigură repetabilitatea ciclurilor de scanare și permite reinițializarea precisă a sistemului, reprezentând o adaptare specifică pentru optimizarea procesului de poziționare.

Componenta de detecție este realizată printr-un contact de limită cu rolă, configurată în regim normal deschis, cu următoarea logică de operare: contactul menține starea deschisă pe parcursul cursei rotorului, comutând în starea închisă la atingerea poziției minime. Implementarea mecanismului cu rolă asigură o tranziție graduală între stări, eliminând riscul oscilațiilor sau al comutărilor false.

Arhitectura senzorului încorporează un sistem de ajustare prin translație, oferind flexibilitate în poziționare fără a necesita modificări structurale ale ansamblului principal.

Fixarea precisă a poziției este realizată prin intermediul unui element de fixare metric M2.5, permițând o calibrare fină și stabilă.

Dezvoltarea componentelor mecanice a fost realizată în mediul CATIA V5, asigurând un control precis asupra parametrilor geometrici. Ansamblul constă în două componente principale:

- O bază fixă, integrată în carcasa existentă prin intermediul unui element de fixare M3

- Un suport mobil pentru senzorul de capăt de cursă, proiectat cu caracteristici de ajustabilitate pentru alinierea optimă cu sistemul de acționare

Materializarea componentelor a fost realizată prin tehnologia de fabricație aditivă (împresare 3D), utilizând materiale compatibile cu structura existentă. Această abordare a facilitat o integrare rapidă și eficientă a modificării, păstrând integritatea structurală a sistemului original. Implementarea acestei soluții tehnice contribuie semnificativ la îmbunătățirea preciziei și fiabilității sistemului de scanare, optimizând performanța în operarea continuă.



Figură 3. Modulul Senzorului de capăt

### 3.2.2.7 Convertor de tensiune

Arhitectura sistemului de alimentare este structurată pe două niveluri de conversie energetică. Sursa primară este reprezentată de rețeaua de alimentare standard de 220V curent alternativ, care este procesată prin intermediul unui convertor AC/DC integrat în încărcător. Acesta realizează transformarea și stabilizarea tensiunii la parametrii de 12V și 3A curent continuu. Această tensiune de 12V constituie magistrala principală de alimentare a sistemului, fiind dedicată componentelor de forță, în special pentru alimentarea ansamblului de drive și motoare pas cu pas.

$$I_{Total} = 2 * I_{Nema17} + 2 * I_{A4988} + I_{Raspberry Pi} + I_{Arducam IMX519} + I_{Ring Light}$$

Unde:

- $I_{Total}$  este curentul total necesar pentru alimentarea sistemului de achiziție

- $I_{Nema17}$  este curentul utilizat pentru motorul stepper Nema17

- $I_{A4988}$  este curentul utilizat de driverul A4988

- $I_{Raspberry Pi}$  este curentul utilizat de Raspberry Pi

- $I_{Arducam IMX519}$  este curentul utilizat de camera

- $I_{Ring\ Light}$  este curentul utilizat de LED

$$I_{Total} = 2 * 1.2A + 2 * 0.02A + 1.3A + 0.1A + 0.2A = 4.04A$$

Analiza consumului energetic al sistemului relevă un curent maxim de operare de 2.82A, acest scenariu fiind calculat pentru situația de sarcină maximă când un singur motor pas cu pas este activ simultan cu toate celelalte componente. Această valoare maximă este determinată de arhitectura funcțională a sistemului, care nu necesită operarea simultană a ambelor motoare.

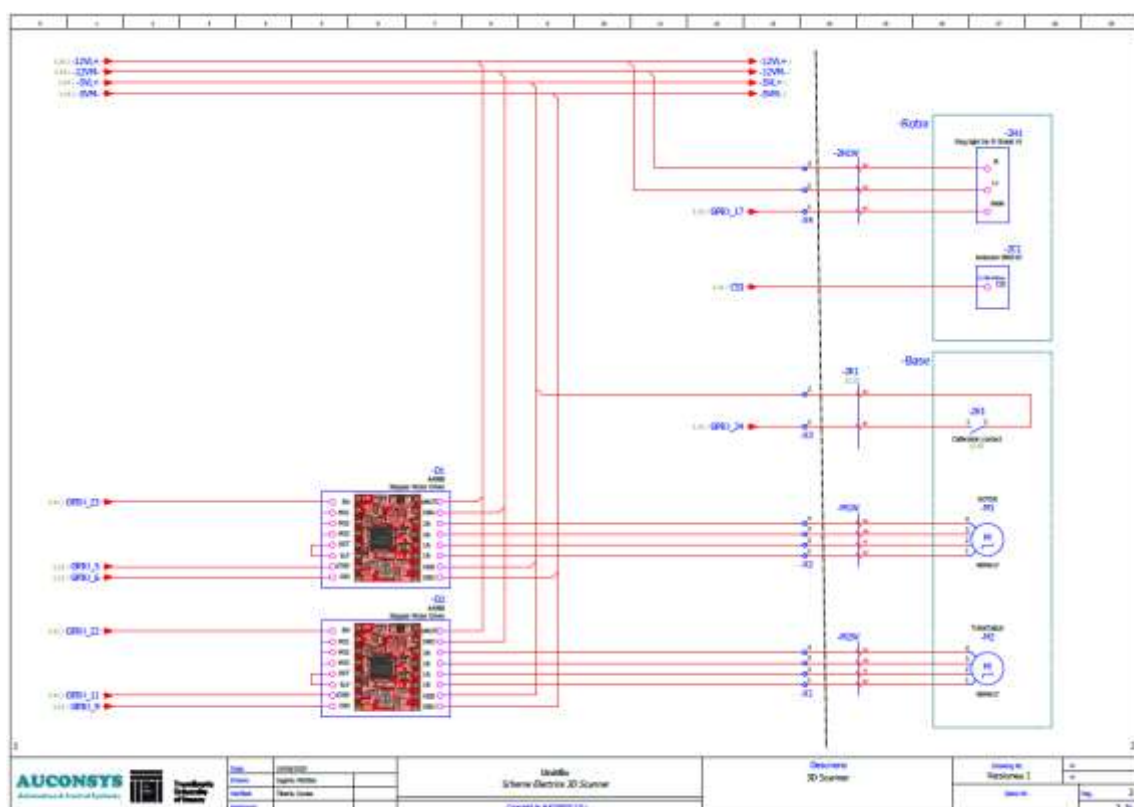
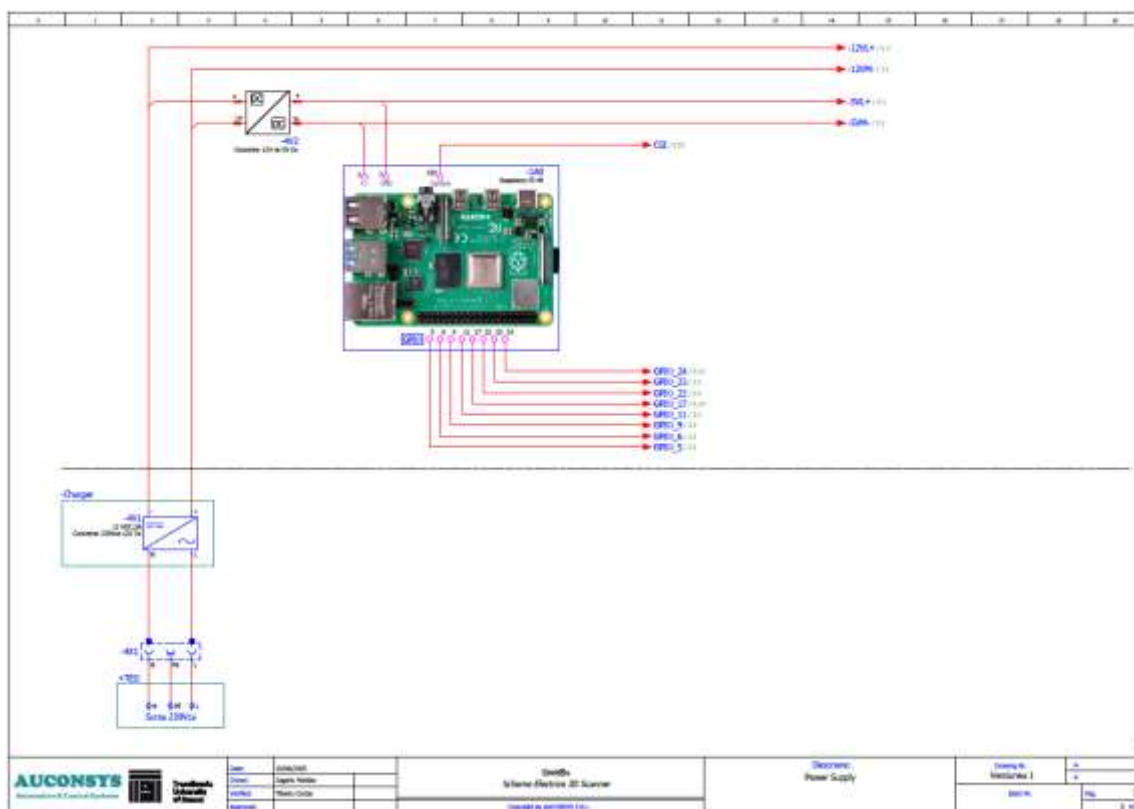
Pentru alimentarea subsistemelor electronice care operează la tensiuni reduse, în special unitatea centrală Raspberry Pi, sistemul implementează o soluție de conversie DC-DC. Acest convertor specializat asigură transformarea eficientă a tensiunii principale de 12V la nivelul de 5V necesar pentru funcționarea optimă a componentelor digitale. Această arhitectură de alimentare a fost proiectată pentru a garanta atât protecția componentelor sensibile, cât și optimizarea eficienței energetice a întregului ansamblu.

#### **3.2.2.8 Stația de lucru**

Stația de lucru folosită în sistem rulează Windows 11 și este echipată cu o placă grafică NVIDIA. Aceste componente sunt importante pentru procesarea rapidă a imaginilor și pentru reconstrucția obiectului 3D. Placa grafică ajută la accelerarea calculelor necesare pentru generarea modelului tridimensional, iar stația de lucru se ocupă de transformarea imaginilor capturate în modele 3D precise și detaliate.

#### **3.2.3 Schema Electrică**

Schema electrică realizată pentru sistemul experimental a fost proiectată în EPLAN 2025 și include toate elementele esențiale pentru funcționarea corectă și sigură a sistemului, facilitând înțelegerea și implementarea corectă a interconexiunilor.



caracteristicile optice ale camerei utilizate. Rotorul are un diametru exterior de 20 cm, iar masa rotativă are o înălțime de 6 cm. În plus, camera necesită o distanță minimă de focalizare de 5 cm pentru a asigura claritatea și detalierea imaginilor capturate.

Astfel, spațiul efectiv disponibil pentru poziționarea obiectului scanat se calculează prin scăderea înălțimii mesei rotative și a distanței minime de focalizare din diametrul rotorului, conform relației matematice:

$$H_{obiect} = D_{Rotor} - H_{Masa\_rotativa} - D_{Focus}$$


unde:

- $L$  obiect este înălțimea obiectului,
- $D$  rotor este diametrul exterior al rotorului
- $H$  masa\_rotativa este înălțimea mesei rotative
- $D$  focus este distanța minimă de focalizare

Înlocuind valorile specifice sistemului:

$$H_{obiect} = 20cm - 6cm - 5cm = 9cm$$

Această limitare dimensională de 9x9x9 cm este esențială pentru a garanta că obiectul este complet cuprins în câmpul vizual al camerei și poate fi focalizat uniform pe întreaga suprafață, evitând astfel erorile de scanare cauzate de depășirea zonei utile de lucru. Respectarea acestor constrângeri optimizează atât calitatea datelor obținute, cât și eficiența procesului de scanare.



Figură 6. Dimensiunile Sistemului de Achiziție

### 3.2.5 Interfața de control

Sistemul de control este implementat printr-o arhitectură client-server bazată pe framework-ul Flask, o soluție Python specializată pentru dezvoltarea aplicațiilor web lightweight. Interfața grafică este construită pe tehnologii web standard - HTML și CSS, rezultând într-un



design minimalist dar eficient, care facilitează configurarea parametrilor critici ai procesului de digitalizare 3D. Automatizarea sistemului include pornirea automată a serverului Flask la inițializarea platformei, asigurând accesibilitatea imediată a interfeței de control. Arhitectura software este structurată în trei componente principale: app.py (logica server), run\_app.bat (script de inițializare) și index.html (interfața utilizator).

Platforma de control operează în mediul Windows și oferă o interfață web accesibilă prin browser, servind ca punct centralizat pentru managementul și monitorizarea procesului de scanare. Interfața permite controlul granular al următorilor parametri operaționali:

- Ajustarea focalizării camerei
- Controlul intensității sistemului de iluminare LED
- Configurarea unghiului de incrementare pentru motoarele pas cu pas, parametru ce determină densitatea capturilor în procesul de rotație

Inițierea secvenței de scanare se realizează prin activarea comenzii "Start" din interfață, care declanșează procesul automatizat de achiziție a imaginilor pe sistemul Raspberry Pi. Această arhitectură asigură un control precis și intuitiv al întregului proces de digitalizare 3D.



*Figură 7. Interfața aplicației*

Arhitectura software a sistemului de control este fundamentată pe framework-ul Flask, o soluție Python specializată pentru dezvoltarea rapidă a aplicațiilor web. Această implementare oferă o interfață web intuitivă, accesibilă prin browser standard, facilitând configurarea parametrilor operaționali și monitorizarea în timp real a procesului de digitalizare 3D.

Structura aplicației Flask este construită în jurul unui obiect central app, responsabil pentru definirea și gestionarea rutelor (endpoints) web și a funcțiilor asociate. Fiecare rută reprezintă un punct de acces URL specific, corelat cu o funcție Python dedicată procesării cererilor HTTP (GET, POST) și generării răspunsurilor corespunzătoare, fie sub formă de pagini HTML, fie ca date JSON.

Din punct de vedere operațional, Flask inițiază un server web local care monitorizează portul 5000 (implicit), procesând cererile browserului și direcționându-le către funcțiile backend corespunzătoare. Această arhitectură permite generarea dinamică a interfeței și procesarea în timp real a interacțiunilor utilizatorului prin intermediul backend-ului Python, care orchestrează comunicarea cu componentele hardware și modulele software auxiliare.

Automatizarea sistemului este implementată prin intermediul unui script batch (run\_app.bat) care asigură lansarea aplicației Flask la inițializarea sistemului. Scriptul execută comanda de pornire a aplicației Python principale (python app.py), activând serverul Flask.

Pentru asigurarea disponibilității permanente, procesul de automatizare este integrat în sistemul de operare Windows prin plasarea unui shortcut către run\_app.bat în directorul de startup al utilizatorului (shell:startup). Această configurație garantează inițializarea automată a serverului Flask la fiecare sesiune de utilizare.

### Rezumat Tehnic:

#### 1. Componente cheie:

- run\_app.bat: Script de inițializare pentru aplicația Flask
- Integrare automată prin directorul startup Windows
- Server web local Flask pentru procesarea cererilor HTTP
- Interfață web interactivă pentru configurare și control
- Backend Python pentru orchestrarea componentelor hardware/software

#### 2. Flux operațional:

- Execuție automată prin sistemul de startup Windows
- Inițializare server web local
- Procesare cereri utilizator prin interfața web
- Transmitere comenzi către subsistemele hardware/software

Această arhitectură oferă o soluție robustă și flexibilă pentru managementul sistemului, îmbinând avantajele unei interfețe web moderne cu capacitățile extensive ale ecosistemului Python și framework-ului Flask.

### 3.2.6 Achiziția de date



Figură 8. Schema funcționării achiziției de date

Procesul de achiziție a datelor pentru reconstrucția 3D fotogrammetrică este implementat local pe platforma Raspberry Pi 4B, utilizând o arhitectură software automatizată. Sistemul integrează multiple componente hardware: actuatoare (motoare pas cu pas), senzori de poziție limită, sistem de captură imagistică de înaltă rezoluție și interfață de comunicație în rețea, realizând astfel un flux operațional complet, de la poziționarea obiectului până la transferul datelor către unitatea de procesare.

Orchestrarea componentelor hardware este realizată printr-un script Python (main.py) care rulează pe Raspberry Pi, asigurând sincronizarea precisă între subsistemul mecanic și cel de achiziție imagistică.

### **Secvența Operațională de Achiziție:**

#### **1. Inițializare Sistem**

- Curățarea automată a directorului de stocare (/home/pi/captures/)
- Pregătirea sistemului pentru o nouă sesiune de captură

#### **2. Calibrare Poziție Inițială**

- Acționarea rotorului vertical în sens antiorar până la detectarea poziției de referință
- Poziționarea în punctul de start predefinit (90°)

#### **3. Execuție Secvență de Scanare**

- Calculul incrementului unghiular bazat pe parametrii N specificați
- Implementarea unei bucle duble de control pentru:
  - \* Rotația platformei (axa Z)
  - \* Ajustarea înălțimii (axa Y)

#### **4. Proces de Captură Imagistică**

- Sincronizare precisă între poziționare și captură
- Menținerea parametrilor optimi de expunere și focalizare

#### **5. Validare Hardware**

- Monitorizarea poziției prin senzori dedicați
- Confirmare completare secvență de achiziție

#### **6. Transfer Date**

- Transmitere set imagini către stația de procesare Windows
- Utilizare conexiune TCP dedicată pe port 5001
- Validare integritate transfer

#### **7. Reinițializare Sistem**

- Curățare spațiu stocare local
- Revenire la poziția inițială

Parametri de Control:

- xx: increment unghiular masă rotativă
- yy: increment unghiular rotor vertical
- Configurabili prin interfața utilizator pentru optimizarea rezoluției și densității capturilor

Această arhitectură asigură un proces robust și flexibil de achiziție a datelor, permițând ajustarea precisă a parametrilor de captură în funcție de cerințele specifice ale obiectului scanat.

$$N_{masa\_rotativa} = \frac{360^{\circ}}{x}$$

Unde N masa rotativa este numarul de poze capturate pe o rotatie a mesei rotative

Rotorul se deplasează pe un arc de  $120^{\circ}$ , efectuând pași de yy grade. Numărul total de poziții ale rotorului este:

$$N_{rotor} = \frac{120^{\circ}}{y}$$


Unde N rotor este numarul de cate ori se invarte masa rotative

Fiecare poziție a rotorului implică o rotație completă a mesei rotative cu capturi la fiecare increment de xx grade, ceea ce conduce la un număr total de imagini:

$$N_{Total} = N_{rotor} * N_{masa\_rotativa} = \frac{120^{\circ}}{y} * \frac{360^{\circ}}{x} = \frac{43200}{x * y}$$

Această relație matematică permite calcularea precisă a numărului total de imagini în funcție de valorile alese pentru xx și yy, care sunt configurate prin interfața utilizator. Astfel, utilizatorul poate anticipa volumul de date generat și poate optimiza parametrii în funcție de cerințele aplicației și capacitatea de procesare.

De exemplu, pentru valorile  $x=45^{\circ}$  și  $y=30^{\circ}$ , numărul total de imagini este 32.



*Figură 9. Traiectoria și pozițiile surprinse de cameră*

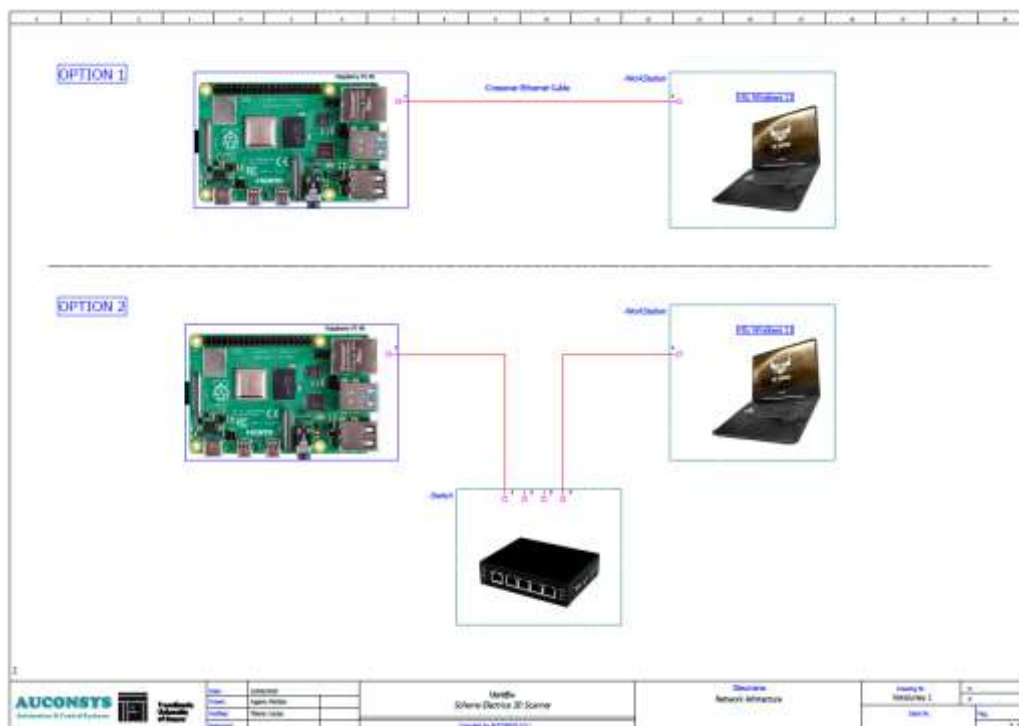
Graficul reprezintă traiectoria și pozițiile punctelor în care camera face fotografii pe suprafața unei sfere, simulând rotațiile pe două axe (masa rotativă și rotorul). Acesta evidențiază continuitatea și ordinea în care sunt capturate imaginile, asigurând o acoperire uniformă și coerentă a perspectivelor asupra obiectului scanat sau fotografiat.

### **3.2.7 Transferul de date**

Arhitectura de comunicație implementată în sistemul de scanare 3D se bazează pe o structură duală server-client dezvoltată în Python, asigurând o comunicare bidirecțională eficientă între componente. Pe partea Raspberry Pi, funcționează un server TCP activ, implementat prin modulele `run_main` și `main`, care gestionează inițierea cererilor către sistemul Windows. În paralel, pe stația Windows rulează un server permanent, dezvoltat prin modulele `windows_server.py` și `START_PROCESS.py`, care procesează aceste cereri și poate, la rândul său, să inițieze comunicații inverse. Această configurație bidirecțională a fost special concepută pentru a optimiza transferul de date, cu accent particular pe transmisia eficientă a imaginilor capturate, implementând un sistem de comunicare la cerere pentru a reduce la minimum încărcarea rețelei.

Conexiunea fizică între Raspberry Pi și stația de lucru PC este realizată prin intermediul unei interfețe Ethernet, oferind flexibilitate în implementare prin suportul pentru multiple configurații de conectivitate. Sistemul poate opera fie prin conexiune directă utilizând un cablu crossover, fie prin intermediul unui switch de rețea, adaptându-se astfel la diverse scenarii de implementare. Această infrastructură de comunicație se bazează pe protocolul TCP/IP, alegere fundamentată pe necesitatea asigurării unui transfer de date fiabil și rapid.

Protocolul TCP/IPv4, component esențial al suitei TCP/IP, joacă un rol crucial în asigurarea integrității comunicației între dispozitive. Acest protocol implementează funcționalități critice pentru aplicații industriale, incluzând mecanisme pentru transferul ordonat al datelor, confirmarea recepției, eliminarea pierderilor de informație și controlul eficient al fluxului și congestiei. Această implementare robustă creează o platformă sigură și eficientă pentru controlul în timp real și transferul securizat al datelor între componentele sistemului de scanare 3D, asigurând astfel performanța și fiabilitatea necesare în procesul de digitalizare tridimensională.



Figură 10. Arhitectura de rețea

Procesul de stabilire a comunicației între dispozitivele sistemului urmează protocolul standardizat TCP cunoscut sub denumirea de "Three-Way Handshake" (strângere de mână în trei pași). Această secvență de inițializare este esențială pentru sincronizarea nodurilor și configurarea parametrilor necesari transferului de date.

Primul pas al secvenței este reprezentat de transmiterea pachetului SYN (Synchronize). În această etapă, dispozitivul care inițiază conexiunea (clientul) transmite un pachet cu flag-ul SYN activat, semnalând intenția de stabilire a conexiunii și propunând un număr inițial de secvență (ISN). Acest pas marchează începutul procesului de sincronizare între cele două noduri. Al doilea pas constă în răspunsul dispozitivului receptor (serverul) prin intermediul unui pachet SYN-ACK (Synchronize-Acknowledge). Acest pachet, care conține ambele flag-uri SYN și ACK activate, îndeplinește două funcții simultane: confirmă recepția cererii inițiale și propune propriul număr de secvență inițial pentru comunicația în sens invers.

Secvența se încheie cu transmiterea unui pachet ACK (Acknowledge) de către client, care confirmă recepția răspunsului serverului. Odată ce acest ultim pas este finalizat cu succes, conexiunea TCP este considerată stabilită și securizată, permițând începerea efectivă a transferului de date între cele două dispozitive.

### **Structura unui pachet TCP/IPv4**

Mecanismul de transmisie a datelor în sistemul implementat se bazează pe segmentarea informației în unități TCP, care sunt ulterior încapsulate în pachete IP. Structura acestor pachete IPv4 este compusă din două elemente fundamentale: headerul IP, care încorporează informațiile necesare pentru rutare, incluzând adresele sursă și destinație, și headerul TCP, care conține detalii esențiale precum porturile utilizate, numerele de secvență, confirmările și flag-urile de control necesare pentru managementul conexiunii.


După stabilirea conexiunii, procesul de transfer implică fragmentarea datelor în segmente de dimensiuni optimizate, tipic de 1460 octeți pentru conexiuni Ethernet, fiecare segment primind un identificator unic sub forma unui număr de secvență. Sistemul implementează un mecanism robust de confirmare, prin care dispozitivul receptor validează recepția fiecărui segment prin transmiterea unui pachet ACK, indicând următorul segment așteptat în secvență. În cazul detectării unor erori sau pierderi de pachete, se activează automat procedura de retransmisie după expirarea unui interval predefinit, asigurând astfel integritatea datelor transmise.

Pentru menținerea stabilității și performanței optime, protocolul TCP implementează două mecanisme principale de control. Primul este controlul fluxului, care reglează volumul de date transmise pentru a preveni supraîncărcarea receptorului, utilizând o fereastră dinamică de recepție. Al doilea mecanism este controlul congestionării, care adaptează rata de transmisie în funcție de condițiile rețelei, optimizând astfel performanța în situații de congestie potențială.

Arhitectura de rețea a sistemului experimental este bazată pe o conexiune directă prin cablu Ethernet crossover între componentele sale principale: o stație Windows 11 configurată cu IP-ul static 192.168.3.1 și un Raspberry Pi 4B cu IP-ul static 192.168.3.85. Comunicarea bidirecțională este implementată prin două canale dedicate: portul 5000 pentru comunicarea de la Raspberry Pi către Windows și portul 5001 pentru comunicarea în sens invers. Această configurație duală permite o separare logică eficientă a fluxurilor de date, facilitând un control precis asupra transferului de informații.

La încheierea procesului de transfer, conexiunea TCP este terminată printr-o secvență de patru pași (Four-Way Termination), care asigură că toate datele au fost transmise și confirmate

corespunzător de ambele părți implicate în comunicare. Această arhitectură robustă, combinată cu utilizarea conexiunii directe prin cablu crossover, elimină latențele adiționale și potențialele interferențe externe, creând astfel un mediu optimal pentru aplicații ce necesită transfer rapid și sigur de date între componentele sistemului.



Figură 11. Schema de comunicație



Figură 12. Cablul Ethernet Crossover

Stabilirea unei conexiuni TCP directe între două dispozitive similare, cum ar fi un PC și un Raspberry Pi, necesită o atenție deosebită la infrastructura fizică de conectare. Această conexiune poate fi realizată fie prin intermediul unui cablu Ethernet de tip crossover, fie prin utilizarea unui echipament de rețea intermediar precum un switch sau router, fiecare metodă având particularitățile sale tehnice.

În cazul conectării directe a două dispozitive de tip DTE (Data Terminal Equipment), precum un calculator și un Raspberry Pi, este necesară utilizarea unui cablu crossover special configurat. Specificitatea acestui cablu constă în organizarea diferită a pinilor la cele două capete, urmând standardele T568A la un capăt și T568B la celălalt. Această configurație asigură încrucișarea corectă a semnalelor de transmisie și recepție, permițând astfel comunicarea directă între dispozitive fără necesitatea unor echipamente intermediare.

Alternativ, conexiunea poate fi stabilită prin intermediul unui switch sau router, situație în care se pot utiliza cabluri standard (straight-through). Aceste echipamente de rețea încorporează circuite specializate care gestionează automat comutarea și inversarea semnalelor, eliminând necesitatea utilizării cablurilor crossover. În plus, această soluție oferă avantajul scalabilității și al funcționalităților de rețea extinse, permițând conectarea simultană a mai multor dispozitive.

Selecția metodei de conectare trebuie să țină cont de contextul specific al implementării. Pentru o conexiune punct-la-punct între două dispozitive similare, un cablu crossover reprezintă soluția optimă din punct de vedere al simplității și al costurilor. În scenarii care necesită conectivitate multiplă sau funcționalități de rețea avansate, utilizarea unui switch sau router devine opțiunea preferată, chiar dacă implică utilizarea unor echipamente suplimentare.



### 3.3 SISTEMUL DE RECONSTRUCȚIE 3D

#### 3.3.1 Etapele procesului de Reconstrucție 3D

După transmiterea imaginilor către sistemul de achiziție, acestea sunt procesate printr-un script Python care utilizează algoritmul de reconstrucție 3D oferit de COLMAP, un software open-source de fotogrametrie. Scriptul automatizează etapele de extragere a caracteristicilor, potrivire și triangulare, facilitând generarea modelului 3D. Scriptul folosit este 3D\_Reconstruction.py.

Pentru a simplifica utilizarea, întregul proces, de la inițializarea sistemului până la obținerea modelului 3D final, este orchestrat de un script Python principal, START\_PROCESS.py. Acesta gestionează pregătirea directoarelor, lansarea proceselor, achiziția și transmiterea datelor, precum și inițierea procesării finale, asigurând o execuție coerentă și automatizată a întregului flux de lucru.

Procesul este complet automatizat și nu necesită informații suplimentare despre poziția sau orientarea camerei, ceea ce îl face extrem de accesibil.

În această secțiune, vom detalia fiecare etapă a pipeline-ului COLMAP, urmărind diagrama bloc prezentată:



Figură 13. Schema funcționării Reconstrucției 3D Colmap

COLMAP este un software open-source pentru reconstrucția 3D automată a scenelor din imagini digitale (Schönberger & Frahm, 2016). Pornind de la un set de fotografii suprapuse, făcute din unghiuri diferite, COLMAP identifică puncte de interes în imagini, le potrivește între ele, estimează pozițiile camerelor și reconstruiește structura 3D a scenei. Reconstrucția 3D reprezintă un proces complex care transformă seturile de imagini bidimensionale în modele tridimensionale complete, folosind principiile fotogrametriei digitale. În contextul acestui proiect, procesul de reconstrucție se bazează pe COLMAP, un software open-source avansat care permite reconstrucția 3D automată a scenelor din imagini digitale. Această soluție a fost aleasă pentru capacitatea sa de a procesa seturi de fotografii suprapuse realizate din unghiuri diferite, identificând în mod automat punctele de interes din imagini și estimând cu precizie pozițiile camerelor pentru a genera structura 3D completă a obiectului scanat.

Procesul de reconstrucție 3D implementat în acest sistem beneficiază de avantajele oferite de integrarea hardware-software optimizată, unde achiziția datelor se realizează într-o

manieră controlată și automatizată. Folosind algoritmi matematici avansați și optimizări hardware, COLMAP poate genera modele 3D precise pornind doar de la seturile de imagini consecutive. În cazul unei imagini de înaltă rezoluție (4000x3000 pixeli), sistemul poate identifica între 10.000 și 50.000 de puncte de interes, care sunt distribuite strategic în zonele cu textură bogată, precum colțuri, muchii și detalii repetitive, asigurând astfel baza necesară pentru o reconstrucție 3D de înaltă fidelitate. Această tehnologie este folosită în fotogrammetrie, robotică, realitate augmentată și alte domenii unde modelele 3D precise sunt esențiale.

Procesul de reconstrucție 3D reprezintă o etapă crucială în transformarea imaginilor bidimensionale într-un model tridimensional coerent și precis. Înainte de a detalia pașii specifici implementați în COLMAP, este important să înțelegem că această reconstrucție se bazează pe principii avansate de computer vision și geometrie computațională. Procesul implică analiza complexă a relațiilor spațiale dintre multiple imagini capturate din unghiuri diferite, identificarea și corelarea punctelor de interes comune, precum și aplicarea unor algoritmi sofisticati de triangulare și optimizare. Succesul reconstrucției depinde în mod direct de calitatea imaginilor de intrare, de gradul lor de suprapunere, precum și de prezența unor caracteristici distinctive în scenă care pot fi identificate și urmărite între diferitele perspective. Această abordare sistematică permite generarea unor modele 3D care păstrează cu fidelitate atât geometria, cât și textura obiectelor scanate.

Procesul de reconstrucție 3D în COLMAP se desfășoară prin parcurgerea mai multor etape distincte și secvențiale. Prima etapă constă în extragerea caracteristicilor (feature extraction), unde software-ul identifică puncte distinctive în fiecare imagine folosind detectori specializați. Urmează etapa de potrivire a caracteristicilor (feature matching), în care punctele similare sunt identificate și corelate între diferitele imagini. A treia etapă implică estimarea pozițiilor camerelor (camera pose estimation), care determină locația și orientarea din care a fost capturată fiecare imagine. În continuare, se realizează triangularea punctelor 3D (sparse reconstruction), creând o reprezentare inițială, dar mai puțin densă a obiectului. Penultima etapă este reconstrucția densă (dense reconstruction), care generează un nor de puncte mult mai detaliat prin analiza pixel cu pixel a imaginilor. În final, ultima etapă constă în generarea suprafeței (meshing), unde norul de puncte dens este transformat într-un model 3D complet, cu suprafețe continue și texturi aplicate.

Procesul COLMAP poate fi împărțit în următoarele etape principale:

### 3.3.2 Extragerea Caracteristicilor

Extragerea caracteristicilor reprezintă primul pas esențial în orice proces de reconstrucție 3D automatizată, inclusiv în pipeline-ul COLMAP. Scopul acestei etape este identificarea unor puncte de interes (keypoints) care sunt unice și stabile în fiecare imagine, astfel încât să poată fi recunoscute și în alte imagini, indiferent de variații de scară, rotație sau iluminare. Aceste puncte servesc drept „ancore” pentru potrivirea între imagini și pentru reconstruirea ulterioară a structurii 3D a scenei.

#### *Algoritmul Utilizat: SIFT*

Algoritmul SIFT (Scale-Invariant Feature Transform) reprezintă o piatră de temelie în procesul de reconstrucție 3D, fiind esențial pentru detectarea și descrierea punctelor cheie din imagini. Procesul începe prin construirea unei piramide de scale gaussiene, unde imaginea originală este procesată progresiv prin filtre de netezire pentru a genera reprezentări la diferite niveluri de detaliu. În fiecare nivel al acestei piramidi, algoritmul identifică puncte de interes prin detectarea extremelor locale în spațiul scale-space, folosind diferența gaussiană (DoG) între nivelurile adiacente. Aceste puncte sunt apoi rafinate prin eliminarea celor cu contrast scăzut sau localizate pe muchii, păstrându-se doar caracteristicile cele mai distinctive și stabile. Pentru fiecare punct rămas, SIFT calculează un descriptor bazat pe distribuția gradientilor locali, organizat într-un vector cu 128 de dimensiuni, care capturează informații despre orientarea și magnitudinea gradientilor în vecinătatea punctului. Această abordare face ca descriptorii să fie invarianți la rotație, scalare și parțial la schimbări de iluminare, ceea ce îi face deosebit de robusți pentru aplicații de reconstrucție 3D, unde obiectele sunt fotografiate din unghiuri și distanțe diferite, în condiții variabile de iluminare.

În COLMAP, extragerea caracteristicilor se bazează pe algoritmul SIFT (Scale-Invariant Feature Transform) (Lowe, 2004). SIFT este recunoscut pentru abilitatea sa de a detecta puncte de interes de tip „blob” cu contrast ridicat, la multiple scări, fiind robust la modificări de scară, rotație și iluminare. Acest lucru îl face ideal pentru aplicații precum reconstrucția 3D, unde imaginile pot fi capturate din unghiuri și distanțe diferite.

#### **Pașii Principali ai Procesului SIFT**

##### **1. Construirea Piramidei de Scale**

Procesul de generare a piramidei de scale reprezintă fundamentul algoritmului SIFT și începe cu aplicarea succesivă a filtrelor gaussiene asupra imaginii originale. Această tehnică, cunoscută sub numele de "scale-space filtering", creează o reprezentare multi-scalară a imaginii,

esențială pentru detectarea caracteristicilor invariante la scală. Imaginea originală este procesată prin convoluție cu kernele gaussiene de dimensiuni crescătoare, rezultând o serie de imagini cu nivele progresive de blur. Fiecare nivel al piramidei reprezintă astfel imaginea la o scară specifică, permițând sistemului să detecteze caracteristici care ar putea apărea la dimensiuni variate în funcție de distanța față de cameră sau de rezoluția imaginii.

Filtrul gaussian este aplicat cu diferite valori ale deviației standard ( $\sigma$ ). Aceste valori sunt alese astfel încât să formeze o progresie geometrică, tipic cu un factor ( $k = \sqrt{2}$ ) între nivelurile consecutive. Această spațiere logaritmică a scalelor asigură o distribuție uniformă a sensibilității la diferite dimensiuni ale caracteristicilor. În practică, piramida este organizată în octave, unde fiecare octavă reprezintă o dublare a valorii  $\sigma$ , iar fiecare octavă este subdivizată în mai multe nivele intermediare (de obicei 3-5 nivele).

Filtrul gaussian bidimensional este definit prin următoarea expresie matematică:

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

*Figură 2. Filtrul gaussian bidimensional*

Pentru aplicații practice, se folosește adesea și forma separabilă a filtrului, care poate fi aplicată secvențial pe rânduri și coloane:

$$G(x, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

$$G(y, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{y^2}{2\sigma^2}}$$

*Figură 3. Formula Filtrului Gaussian aplicată secvențial pe rânduri și coloane*

Proprietățile importante ale filtrului gaussian includ:

- Este separabil (poate fi aplicat independent pe x și y)
- Este simetric radial
- Are suma coeficienților egală cu 1

Pentru eficiență computațională și reducerea redundanței, după fiecare octavă completă, imaginea este sub-eșantionată cu un factor de 2, reducând dimensiunea sa la jumătate. Acest proces de sub-eșantionare este precedat de un filtru gaussian corespunzător pentru a evita aliasing-ul. Structura rezultată, cunoscută sub numele de piramidă gaussiană, permite algoritmului să detecteze și să compare caracteristici la diferite scale într-un mod computațional

eficient. Mai mult, această abordare multi-scalară asigură că punctele de interes pot fi detectate și localizate cu precizie, indiferent de mărimea lor aparentă în imagine sau de variațiile de scală între diferite imagini ale aceluiași obiect. Implementarea practică a acestei etape necesită o atenție deosebită la alegerea parametrilor, precum numărul de octave, numărul de nivele per octavă și valoarea inițială a  $\sigma$ . Acești parametri influențează direct calitatea și cantitatea caracteristicilor detectate, precum și timpul de procesare necesar. În general, se recomandă utilizarea a 4 octave și 5 nivele per octavă pentru imagini de rezoluție medie, cu o valoare inițială a  $\sigma$  de 1.6, acestea fiind valorile care au demonstrat empiric cel mai bun echilibru între performanță și cost computațional.

## 2. Diferența Gaussienilor (DoG)

După construirea piramidei de scale, se calculează Diferența Gaussienilor (DoG) între imagini la scale apropiate. Formula utilizată este:

$$D(x,y,\sigma) = L(x,y,k\sigma) - L(x,y,\sigma) \quad D(x,y,\sigma) = L(x,y,k\sigma) - L(x,y,\sigma)$$

unde  $L(x,y,\sigma)$  este imaginea convoluată cu o funcție Gaussiană de scară  $\sigma$ , iar  $k$  este un factor constant (de obicei 2.2). Diferența Gaussienilor evidențiază zonele cu variații locale mari de intensitate – tipic pentru colțuri, muchii sau alte structuri locale stabile.

## 3. Detectarea Extremelor Locale

În acest pas, algoritmul caută maxime și minime locale în spațiul tridimensional ( $x$ ,  $y$ , scară) al piramidei DoG. Fiecare pixel dintr-o imagine DoG este comparat cu vecinii săi din același nivel de scară, precum și cu vecinii din nivelurile de scară adiacente (în total 26 de vecini). Un pixel este considerat extremă locală dacă valoarea sa este mai mare sau mai mică decât toți vecinii săi. După identificarea acestor puncte potențiale de interes, algoritmul implementează un proces riguros de filtrare pentru a elimina punctele instabile sau ne semnificative. Acest proces include două etape principale de filtrare: prima este filtrarea pe bază de contrast, unde se elimină punctele cu răspuns DoG slab, considerate zgomot sau artefacte de iluminare. A doua etapă implică filtrarea pe margini, unde se folosește matricea Hessian pentru a evalua curbura locală, eliminând punctele situate pe margini unde curbura este foarte diferită pe cele două axe principale, deoarece acestea nu sunt bine localizate și pot genera potriviri false. În scene complexe și detaliate, numărul de keypoints crește semnificativ, îmbunătățind acuratețea reconstrucției. În practică, pentru o imagine de înaltă rezoluție de 4000x3000 pixeli, acest proces poate identifica zeci de mii de puncte de interes distincte, care vor servi ulterior ca bază pentru procesul de reconstrucție 3D.

#### 4. Filtrarea Punctelor Instabile

Procesul de filtrare a punctelor instabile reprezintă o etapă critică în algoritmul SIFT, fiind esențial pentru asigurarea calității și fiabilității reconstrucției 3D. Această etapă se concentrează pe rafinarea setului inițial de puncte de interes (keypoints) pentru a păstra doar acele caracteristici care sunt cu adevărat relevante și stabile. Scopul principal este identificarea unor puncte de interes care sunt unice și robuste în fiecare imagine, capabile să fie recunoscute în alte imagini, indiferent de variațiile de scară, rotație sau iluminare.

##### *Analiza și Filtrarea bazată pe Contrast*

În prima etapă de filtrare, algoritmul evaluează răspunsul DoG (Difference of Gaussian) pentru fiecare punct detectat. Această analiză este crucială pentru eliminarea punctelor cu contrast slab, care pot fi rezultatul zgomotului din imagine sau al artefactelor de iluminare. Procesul este deosebit de important în zonele uniforme ale imaginii, unde numărul de keypoints trebuie să fie redus natural, evitând astfel detecțiile false care ar putea compromite calitatea reconstrucției finale.

##### *Evaluarea Stabilității prin Matricea Hessian*

Un aspect crucial al procesului de filtrare implică utilizarea matricei Hessian pentru evaluarea curburilor locale. Această analiză matematică sofisticată permite identificarea și eliminarea punctelor situate pe margini, unde curbura prezintă diferențe semnificative pe axele principale. Punctele care trec de acest filtru demonstrează o stabilitate mai mare și sunt mai probabil să genereze potriviri corecte în etapele ulterioare ale procesului de reconstrucție.

##### *Impactul asupra Densității și Distribuției Punctelor*

În practică, pentru o imagine de înaltă rezoluție (4000x3000 pixeli), algoritmul poate identifica inițial între 10.000 și 50.000 de puncte de interes. După aplicarea filtrelor, punctele rămase sunt distribuite predominant în zonele cu textură bogată, cum ar fi colțuri, muchii și detalii repetitive. În scene complexe și detaliate, numărul final de keypoints poate crește semnificativ, contribuind la îmbunătățirea acurateței reconstrucției.

##### *Optimizarea și Validarea*

Pentru a asigura robustețea procesului, fiecărui punct care trece de filtrele inițiale i se atribuie o orientare dominantă, calculată pe baza gradientului local de intensitate. Această orientare este determinată prin analiza direcției și magnitudinii gradientului într-o zonă circulară din jurul punctului. În cazurile unde există multiple maxime apropiate, un keypoint poate primi mai multe orientări, crescând astfel robustețea la rotații și transformări geometrice.

## 5. Atribuirea Orientării

În cadrul algoritmului SIFT, procesul de atribuire a orientării pentru punctele de interes reprezintă o etapă fundamentală pentru asigurarea robusteții la transformări geometrice. SIFT este recunoscut pentru capacitatea sa de a detecta și caracteriza puncte de interes care rămân stabile în ciuda modificărilor de scară, rotație și iluminare. Această caracteristică este esențială în contextul reconstrucției 3D, unde imaginile sunt capturate din unghiuri și distanțe variate.

Pentru fiecare punct de interes identificat, algoritmul implementează o analiză detaliată a gradientului local de intensitate. Procesul implică examinarea unei zone circulare în jurul fiecărui keypoint, unde se analizează atât direcția, cât și magnitudinea gradientului. Această analiză este structurată prin construirea unei histograme de orientări care conține 36 de bin-uri, fiecare reprezentând un interval de 10 grade. Această discretizare precisă a orientărilor permite o caracterizare detaliată a distribuției gradientilor locali.

Un aspect important al acestui proces este capacitatea sa de a gestiona cazurile complexe. În situațiile unde se identifică multiple maxime apropiate în histograma de orientări, algoritmul poate atribui mai multe orientări aceluiși keypoint. Această caracteristică sporește semnificativ robustețea sistemului la rotații, permițând o mai bună adaptare la variațiile geometrice ale scenei. În practică, acest mecanism contribuie la îmbunătățirea acurateței reconstrucției, în special în scenele complexe și detaliate unde numărul de keypoints poate fi substanțial.

## 6. Calculul Descriptorului

Pentru fiecare keypoint identificat, algoritmul generează un descriptor numeric complex care caracterizează textura locală din vecinătatea punctului. Această caracterizare se realizează prin împărțirea zonei din jurul punctului într-o grilă de 4x4 celule, rezultând 16 subregiuni distincte. Pentru fiecare subregiune, se construiește o histogramă cu 8 direcții pentru gradientul local, iar concatenarea acestor histograme produce un vector descriptor cu 128 de dimensiuni (4x4x8). Această structurare detaliată permite capturarea unor informații bogate despre distribuția și orientarea gradientilor locali în vecinătatea punctului de interes.

### Robustețea și Aplicabilitatea în Reconstrucția 3D

Descriptorii SIFT sunt proiectați să fie suficient de distinctivi pentru a permite potrivirea robustă între imagini. În practică, această caracteristică este esențială pentru identificarea perechilor de puncte din imagini diferite care corespund aceluiși punct fizic din scenă. Eficiența acestui sistem este demonstrată în special în scene complexe și detaliate, unde numărul mare de keypoints contribuie la îmbunătățirea acurateței reconstrucției. Pentru imagini de înaltă rezoluție

(4000x3000 pixeli), sistemul poate procesa între 10.000 și 50.000 de puncte de interes, fiecare având asociat un descriptor SIFT distinct.

## **7. Exemplu Practic și Observații**

Într-o imagine de 4000x3000 pixeli, COLMAP poate extrage între 10.000 și 50.000 de puncte de interes, fiecare având un descriptor SIFT asociat. Aceste puncte sunt distribuite în zone cu textură bogată (colțuri, muchii, detalii repetitive) și vor servi ca bază pentru potrivirea între imagini și reconstruirea scenei 3D. Astfel, au fost observate următoarele aspecte: în zonele uniforme (de exemplu, cer sau pereți netezi), numărul de keypoints va fi redus, iar în scenele complexe și detaliate, numărul de keypoints crește, îmbunătățind acuratețea reconstrucției.

## **8. Rolul Extragerii Caracteristicilor în COLMAP**

Extragerea caracteristicilor reprezintă o componentă fundamentală în pipeline-ul COLMAP, având un rol crucial în procesul de reconstrucție 3D. Această etapă esențială permite sistemului să identifice și să urmărească puncte distincte între multiple imagini, chiar când acestea sunt capturate din perspective și la scale diferite, asigurând astfel baza pentru întregul proces de reconstrucție.

În centrul acestui proces se află detectorul și descriptorul SIFT (Scale-Invariant Feature Transform), care este implementarea implicită în COLMAP. Acest algoritm sofisticat generează vectori descriptori cu 128 de dimensiuni pentru fiecare punct cheie identificat în imagini. Puterea SIFT constă în capacitatea sa de a fi invariant la multiple transformări, incluzând rotații complete de 360 de grade, modificări de scală până la un factor de 2, transformări afine moderate și variații de iluminare. Această robustețe este obținută prin construirea unei piramide Gaussiene multi-scală pentru fiecare imagine și calcularea orientărilor dominante bazate pe gradientii locali.

Procesul de extragere a caracteristicilor furnizează fundamentul esențial pentru etapele ulterioare ale reconstrucției 3D. Punctele cheie identificate servesc ca ancore pentru triangularea pozițiilor 3D și sunt utilizate în calculul matricelor fundamentale și esențiale între perechile de imagini. Aceste informații sunt critice pentru estimarea pozelor relative ale camerelor și pentru procesul de optimizare globală prin bundle adjustment. Calitatea și densitatea caracteristicilor extrase influențează direct atât acuratețea reconstrucției finale, cât și completitudinea modelului 3D rezultat.

Un aspect important al procesului este facilitarea matching-ului și verificării geometrice. Descriptorii SIFT permit identificarea rapidă și precisă a corespondențelor între imagini, utilizând structuri de date optimizate precum k-d trees. Pentru asigurarea robusteții, se aplică teste geometrice precum RANSAC, care elimină potrivirile eronate. Corespondențele validate contribuie



la construirea grafului de scene, element crucial în ghidarea procesului de reconstrucție incrementală.

În contextul procesării la scară largă, sistemul de extragere a caracteristicilor demonstrează avantaje semnificative. Procesul poate fi paralelizat eficient, permițând procesarea simultană a mai multor imagini. Caracteristicile pot fi extrase și stocate independent pentru fiecare imagine, iar natura compactă a descriptorilor reduce semnificativ cerințele de memorie pentru seturile mari de date. Această eficiență în procesare face posibilă aplicarea COLMAP în proiecte de mare anvergură, menținând în același timp precizia și calitatea rezultatelor.

Prin urmare, etapa de extragere a caracteristicilor în COLMAP nu este doar o componentă tehnică necesară, ci reprezintă fundamentul care permite întregului sistem să funcționeze eficient și precis. Succesul reconstrucției 3D finale depinde în mare măsură de robustețea și acuratețea acestei etape inițiale, subliniind importanța sa critică în întregul proces de Structure-from-Motion.

### **3.3.3 Potrivirea caracteristicilor**

Potrivirea caracteristicilor în COLMAP reprezintă un proces fundamental în cadrul pipeline-ului de reconstrucție 3D, având ca obiectiv principal identificarea și stabilirea corespondenței între punctele care reprezintă aceeași entitate fizică în imagini diferite. Acest proces este esențial pentru calculul geometriei epipolare între imagini, triangularea punctelor 3D și estimarea precisă a pozițiilor și orientărilor camerelor, contribuind astfel la construirea unei reprezentări coerente a structurii scenei tridimensionale.

Strategia de potrivire implementată în COLMAP este una complexă și sofisticată, combinând multiple tehnici pentru asigurarea robusteții și eficienței. Procesul începe cu căutarea vecinilor apropiați, utilizând structuri de date optimizate precum k-d trees sau FLANN pentru identificarea eficientă a celor mai apropiați doi vecini din imaginea țintă pentru fiecare descriptor din imaginea sursă. Distanța între descriptori este calculată folosind metrica L2 (Euclidiană), oferind o măsură precisă a similarității între punctele caracteristice.

Un aspect crucial al procesului este filtrarea potrivirilor prin aplicarea regulii lui Lowe, care utilizează un prag empiric de 0.8 pentru raportul între distanțele la cel mai apropiat și al doilea cel mai apropiat vecin. Această regulă este urmată de o verificare geometrică riguroasă utilizând algoritmul RANSAC, care estimează matricea fundamentală între perechile de imagini și elimină

outlieri. Procesul este completat de filtre suplimentare pentru eliminarea potrivirilor duplicate și verificarea reciprocității între imagini.

Pentru optimizarea performanței și gestionarea eficientă a resurselor, COLMAP implementează diverse strategii de accelerare și management al memoriei. Procesul de potrivire este paralelizat pentru multiple perechi de imagini, utilizează structuri de date ierarhice pentru căutare eficientă și implementează scheme de indexare pentru reducerea complexității computaționale. În cazul seturilor mari de imagini, se aplică procesarea în loturi și strategii de compresie pentru optimizarea utilizării memoriei.

În practică, rezultatele potririilor caracteristicilor pot fi cuantificate prin statistici concrete. De exemplu, într-un scenariu tipic unde o imagine cu 20.000 de puncte cheie este comparată cu una având 18.000 de puncte, procesul începe cu aproximativ 15.000 de potriviri inițiale. După aplicarea regulii lui Lowe, numărul se reduce la aproximativ 12.000, iar în urma verificării geometrice prin RANSAC, rămân în jur de 8.000 de perechi valide. Calitatea acestor potriviri este influențată de factori precum suprapunerea între imagini, condițiile de iluminare, schimbările de perspectivă și calitatea texturii scenei.

Importanța acestei etape în pipeline-ul COLMAP nu poate fi subestimată, întrucât calitatea potrivirilor influențează direct precizia reconstrucției 3D finale, robustețea la zgomot și outlieri, precum și completitudinea modelului rezultat. Potrivirile validate sunt utilizate în etapele ulterioare pentru estimarea pozelor camerelor, triangularea punctelor 3D și optimizarea globală prin bundle adjustment. Această etapă critică stă la baza succesului întregului proces de reconstrucție Structure-from-Motion, iar performanța sa are un impact direct asupra calității rezultatului final.

### **3.3.4 Estimarea poziției camerei**

Estimarea pozițiilor camerelor prin Structure-from-Motion (SfM) reprezintă un proces sofisticat și esențial în cadrul reconstrucției 3D, transformând informațiile bidimensionale din imagini în reprezentări tridimensionale coerente ale scenei și pozițiilor camerelor. Această etapă fundamentală îmbină concepte complexe din geometria proiectivă cu tehnici avansate de optimizare numerică, având ca scop obținerea unor rezultate precise și robuste care să reflecte cu acuratețe realitatea fizică a scenei capturate.

Fundamentul teoretic al SfM se bazează pe principii solide din geometria proiectivă, în special pe conceptul de geometrie epipolară, care descrie relațiile matematice între diferitele perspective ale aceleiași scene. Această relație este codificată prin matricea fundamentală  $F$ , care

leagă punctele corespondente din diferite imagini prin ecuația fundamentală. În cazurile în care parametrii interni ai camerei sunt cunoscuți, se poate calcula matricea esențială  $E$ , care oferă o reprezentare mai directă a relației geometrice între camere, permițând extragerea informațiilor despre rotație și translație.

Pipeline-ul SfM începe cu o etapă crucială de inițializare, în care se selectează cu atenție perechea inițială de imagini bazată pe criterii precum numărul de potriviri robuste și configurația geometrică favorabilă. Procesul continuă cu estimarea matricei fundamentale utilizând algoritmul 8-punct împreună cu RANSAC pentru robustețe la outlieri. Din matricea esențială rezultată se extrag parametrii de rotație și translație, care definesc pozițiile relative ale camerelor. Aceste informații sunt apoi utilizate pentru triangularea punctelor 3D, folosind metode precum Direct Linear Transform și minimizând erorile de reproiecție.

Un aspect crucial al procesului este optimizarea globală prin Bundle Adjustment, care rafinează simultan toate parametrii estimați: pozițiile și orientările camerelor, coordonatele punctelor 3D și, opțional, parametrii intrinseci ai camerelor. Această optimizare complexă utilizează funcții robuste de cost și tehnici avansate de minimizare pentru a reduce erorile de reproiecție și a îmbunătăți coerența globală a reconstrucției. COLMAP implementează această optimizare într-o manieră incrementală, alternând între adăugarea de noi camere, triangularea punctelor și rafinarea parametrilor. Implementarea practică în COLMAP include strategii sofisticate pentru managementul outlierilor și optimizări pentru scalabilitate. Sistemul utilizează filtre bazate pe eroarea de reproiecție, verificări de consistență geometrică și scheme robuste de estimare pentru a asigura calitatea rezultatelor. Pentru a gestiona eficient seturi mari de date, se implementează strategii de paralelizare a calculelor și tehnici de management eficient al memoriei.

Rezultatele procesului pot fi evaluate prin diverse metrice cantitative, precum eroarea medie de reproiecție, care în implementări bune este tipic sub un pixel, numărul de puncte 3D triangulate cu succes și procentul de imagini aliniate corect. În cazuri practice, pentru o pereche tipică de imagini, se pot obține rotații relative de aproximativ 15 grade, translații de 0.5 metri și mii de puncte 3D reconstituite cu erori de reproiecție sub un pixel. Procesul prezintă diverse provocări care trebuie abordate cu atenție, precum gestionarea scenelor cu textură limitată, tratarea ocluziunilor și a mișcărilor independente, precum și rezolvarea ambiguităților de scală. De asemenea, aspectele legate de performanță, precum optimizarea timpului de calcul și reducerea consumului de memorie, sunt cruciale pentru aplicabilitatea practică a sistemului.

Succesul în abordarea acestor provocări determină în mare măsură calitatea reconstrucției 3D finale, făcând din această etapă un element critic în pipeline-ul COLMAP.

### 3.3.5 Reconstrucția densă

Reconstrucția densă prin Multi-View Stereo (MVS) reprezintă etapa finală și crucială în pipeline-ul de reconstrucție 3D urmează metodologia descrisă de Furukawa și Ponce (2010) transformând reconstrucția inițială bazată pe puncte sparse într-un model tridimensional detaliat și dens. Această etapă valorifică pozițiile camerelor estimate anterior pentru a genera o reprezentare completă și detaliată a scenei, capturând subtilitățile geometrice care nu au fost evidențiate în etapele anterioare. Procesul MVS se bazează pe principiul fundamental al stereo-corespondenței, extins la multiple vederi. În timp ce reconstrucția inițială Structure-from-Motion operează cu puncte caracteristice distincte, MVS analizează fiecare pixel din imaginile de intrare, estimând informații de adâncime pentru a crea o reprezentare densă a suprafețelor scenei. Această abordare exhaustivă permite capturarea detaliilor fine și a variațiilor subtile ale geometriei, rezultând într-o reconstrucție mult mai completă și mai precisă. Selecția optimă a viewurilor pentru reconstrucția multi-view stereo urmează principiile stabilite de Schönberger et al. (2016), maximizând calitatea reconstrucției finale.


Algoritmul PatchMatch Stereo, implementat în COLMAP, reprezintă nucleul procesului de reconstrucție densă. Această abordare inovativă combină căutarea eficientă în spațiul soluțiilor cu propagarea locală a informațiilor de adâncime. Pentru fiecare pixel din imaginile de referință, algoritmul estimează valoarea optimă a adâncimii prin evaluarea similarității cu regiunile corespondente din imaginile vecine. Procesul utilizează o strategie de optimizare iterativă care alternează între propagarea ipotezelor de adâncime între pixeli vecini și căutări aleatorii în spațiul soluțiilor, convergând rapid către estimări robuste ale geometriei scenei. Implementarea practică în COLMAP include multiple optimizări și rafinări ale procesului de bază. Sistemul utilizează măsuri de similaritate robuste pentru a gestiona variațiile de iluminare și perspectivă, implementează strategii de filtrare pentru eliminarea zgomotului și a outlierilor, și aplică tehnici de fuziune pentru combinarea coerentă a informațiilor din multiple vederi. Un aspect crucial este utilizarea unei abordări multi-scale, care permite atât capturarea detaliilor fine, cât și menținerea coerenței la scară mai largă.

Rezultatul final al procesului MVS este un nor dens de puncte 3D care poate conține milioane de puncte, reprezentând cu fidelitate geometria scenei originale. Acest nor dens poate fi ulterior procesat pentru a genera mesh-uri poligonale, hărți de normală și alte reprezentări utile

în aplicații practice. Calitatea reconstrucției dense este influențată de factori precum rezoluția imaginilor de intrare, acuratețea calibrării camerelor, textura scenei și condițiile de iluminare. Provocările specifice în reconstrucția densă includ gestionarea eficientă a memoriei pentru seturi mari de date, tratarea zonelor cu reflexii sau transparență, și menținerea coerenței în regiuni cu texturi repetitive sau ambigue. COLMAP abordează aceste provocări prin implementarea de strategii de procesare out-of-core, utilizarea de euristici robuste pentru detectarea și eliminarea artefactelor, și aplicarea de constrângeri de regularizare care promovează soluții plauzibile din punct de vedere fizic.

Pentru procesarea eficientă a seturilor mari de imagini, sistemul implementează optimizări inspirate din lucrarea lui Agarwal et al. (2011), care demonstrează posibilitatea reconstrucției 3D la scară mare.

Importanța acestei etape finale nu poate fi subestimată, întrucât calitatea reconstrucției dense determină în mare măsură utilitatea practică a modelului 3D rezultat. Fie că este vorba despre documentare arhitecturală, modelare pentru realitate virtuală sau analiză industrială, capacitatea de a genera reconstrucții dense precise și complete este esențială pentru succesul aplicațiilor din lumea reală.



Figură 14. Schema bloc pentru reconstrucția densă

În contextul reconstrucției dense, rezultatele practice demonstrează capacitatea remarcabilă a sistemului de a procesa imagini de înaltă rezoluție și de a genera reprezentări 3D detaliate. Pentru o imagine tipică de 4000x3000 pixeli, ceea ce înseamnă 12 milioane de pixeli potențiali, algoritmul PatchMatch Stereo realizează o analiză comprehensivă, estimând valori de adâncime pentru fiecare pixel valid din imagine. Acest proces intensiv din punct de vedere computațional transformă informația bidimensională într-un nor dens de puncte tridimensionale, capturând subtilități geometrice precum texturi fine ale suprafețelor, muchii și detalii arhitecturale care ar fi fost pierdute în reconstrucția inițială bazată doar pe puncte caracteristice. Norul de puncte rezultat poate conține milioane de puncte 3D precise, fiecare având asociate informații de culoare și normală, putând fi exportat în formate standard precum PLY sau OBJ pentru vizualizare în software-uri specializate sau pentru prelucrări ulterioare cum ar fi generarea de mesh-uri, aplicarea de texturi sau integrarea în diverse aplicații de realitate virtuală și augmentată.

Acest proces integrat, de la extragerea caracteristicilor până la reconstrucția densă, face din COLMAP un instrument puternic și flexibil pentru reconstrucția 3D automată. Folosind algoritmi matematici avansați și optimizări hardware, COLMAP poate genera modele 3D precise pornind doar de la un set de imagini consecutive.

### 3.3.5 Editarea modelului 3D

După ce COLMAP îți generează un fișier PLY, poți folosi MeshLab pentru a pregăti acest model 3D pentru imprimarea 3D, transformându-l într-un fișier STL gata de printare. MeshLab este un software open-source puternic, specializat în editarea și curățarea mesh-urilor 3D, oferind toate uneltele necesare pentru a face modelul „printabil”.

Primul pas este să importarea fișierul PLY în MeshLab. Odată încărcat, acesta se poate roti, mări sau micșora modelul pentru a inspecta detaliile și eventualele probleme vizuale. MeshLab oferă diferite moduri de afișare, cum ar fi puncte, wireframe sau suprafață netedă, care poate ajuta la a vedea clar structura mesh-ului.

Scanările 3D includ adesea puncte sau suprafețe nedorite, cum ar fi fundalul sau obiecte din jur. În MeshLab, poți selecta aceste părți folosind funcția „Select Vertices” din meniul Edit. Selectezi manual sau cu ajutorul unor filtre punctele nedorite, apoi le ștergi cu tasta Delete. Această etapă este esențială pentru a păstra doar obiectul de interes și a evita printarea unor părți inutile.

Pentru imprimare 3D, modelul trebuie să fie „water-tight”, adică fără găuri sau margini deschise. În MeshLab, poți folosi filtre din meniul Filters > Cleaning and Repairing, cum ar fi „Close Holes” pentru a închide automat găurile din mesh. Dacă există muchii libere („boundary edges”), acestea trebuie identificate și corectate, altfel imprimanta 3D va avea probleme la interpretarea volumului.

Scanările pot genera modele foarte dense, cu milioane de fețe, ceea ce poate îngreuna procesul de slicing și imprimare. MeshLab oferă filtre de decimare, cum ar fi „Quadric Edge Collapse Decimation”, care reduc numărul de fețe păstrând forma generală a obiectului. Această optimizare face modelul mai ușor de gestionat și imprimat, fără pierderi semnificative de detaliu.

Este important ca toate fețele să aibă normalele orientate spre exterior. În MeshLab, poți verifica și corecta orientarea normalelor cu filtre din Filters > Normals, cum ar fi „Re-Orient all faces coherently”. De asemenea, asigură-te că modelul este scalat corect în unitățile dorite (milimetri, centimetri), ajustând dimensiunile dacă este nevoie.

După toate aceste modificări, poți exporta modelul în format STL, care este standardul pentru imprimarea 3D. În MeshLab, folosești opțiunea File > Export Mesh As..., alegi STL și salvezi fișierul pregătit pentru slicing.

În concluzie, MeshLab este un instrument esențial pentru transformarea unui fișier PLY brut într-un model 3D curat, închis și optimizat, gata pentru imprimarea 3D. Curățarea fundalului, închiderea găurilor, simplificarea mesh-ului și corectarea normalelor sunt pași obligatorii pentru a asigura o imprimare fără erori și de calitate.

## 4. REZULTATE EXPERIMENTALE

### 4.1 PREGĂTIREA OBIECTELOR SCANATE



Figură 15. Obiect Pregătit



Figura 16. Cilindru plastic



Figura 17. Minifigurină mată

Calitatea procesului de scanare 3D este puternic influențată de caracteristicile obiectului scanat. Materialele cu textură bogată în detalii și suprafețe mate oferă rezultate optime în procesul de digitalizare. Un exemplu relevant este lemnul, care datorită texturii sale naturale și detaliate permite o reconstrucție 3D precisă.

În contrast, obiectele cu suprafețe lucioase, precum cilindrii din plastic, prezintă provocări semnificative în procesul de scanare. Reflexiile luminii pe suprafețele lucioase generează neuniformități în captură, iar algoritmul de reconstrucție poate interpreta eronat punctele reflectorizante ca fiind comune, chiar dacă acestea aparțin unor zone opuse ale obiectului. Acest fenomen conduce la apariția unor imperfecțiuni și goluri în modelul 3D final.

### 4.2 CALIBRAREA AUTOFOCUSULUI ȘI A LUMINIOZITAȚII



Figură 18. Iluminare Auxiliară și fundal gri



Figură 19. Test fundal alb



Figură 20. Test fundal negru



Focusul și luminozitatea sunt esențiale pentru scanarea 3D, influențând direct calitatea și acuratețea datelor capturate. Un focus precis asigură claritatea detaliilor obiectului scanat, permițând senzorilor să detecteze corect contururile și textura suprafeței. Dacă focusul este necorespunzător, rezultatul scanării poate fi neclar, cu detalii pierdute sau deformate, ceea ce afectează fidelitatea modelului 3D.

Luminozitatea adecvată este crucială pentru captarea corectă a informațiilor vizuale. Un nivel optim de iluminare ajută senzorii să distingă diferențele de strălucire și textură ale obiectului, iar o iluminare insuficientă sau excesivă poate genera umbre, reflexii sau zone supraexpuse care perturbă procesul de scanare. De exemplu, în medii cu lumină foarte slabă sau foarte puternică, sistemele de scanare pot întâmpina dificultăți în detectarea corectă a detaliilor, ceea ce duce la erori în modelul final.

Pentru optimizarea calității scanării 3D, sistemul a fost dotat cu două surse LED montate în stânga și în dreapta obiectului scanat. Aceste surse de lumină oferă control asupra intensității luminoase și a temperaturii de culoare. În procesul de optimizare, s-au testat trei variante de fundal - alb, gri și negru, experimentele demonstrând că fundalul gri oferă cele mai bune rezultate pentru majoritatea obiectelor scanate.

### 4.3 REZULTATELE RECONSTRUCȚIEI 3D



Figură 21. Norul de puncte



Figură 22. Scanare eșuată



Figură 23. Mesh Corect



Figură 24. Mesh eronat

Imaginile prezentate ilustrează diferite etape ale procesului de scanare și reconstrucție 3D. Prima imagine arată norul de puncte generat în urma procesării fotogrammetrice, reprezentând punctele comune identificate din multiple fotografii. A doua imagine prezintă un exemplu de scanare eșuată, unde calitatea slabă a capturilor sau caracteristicile nefavorabile ale obiectului au condus la rezultate imprecise. Ultimele două imagini prezintă comparația între un mesh corect generat și unul eronat, evidențiind importanța calității datelor de intrare și a parametrilor de procesare pentru obținerea unui model 3D precis.

Dezvoltarea și implementarea sistemului de scanare 3D prezentat în această lucrare se înscrie în tendința actuală de democratizare a tehnologiilor de digitalizare tridimensională. În contextul în care scanarea 3D devine tot mai accesibilă și răspândită, cu aplicații diverse în inginerie, design de produs și arheologie digitală, sistemul propus oferă o alternativă viabilă și flexibilă față de soluțiile comerciale costisitoare. Fotogrametria a evoluat semnificativ, transformându-se dintr-un instrument dedicat exclusiv cartografiei într-o soluție versatilă, aplicabilă într-o varietate de contexte operaționale și comerciale. În special în sectoarele energetic și minier, această tehnologie oferă soluții eficiente pentru inspecții la distanță, reducând riscurile pentru personal și timpul de intervenție, fiind tot mai frecvent integrată cu tehnologii emergente precum inteligența artificială, realitatea augmentată și digital twin.

Performanța sistemului dezvoltat este susținută de integrarea software-ului COLMAP, care s-a dovedit a fi un instrument puternic și flexibil pentru reconstrucția 3D automată. Procesul este complet automatizat și nu necesită informații suplimentare despre poziția sau orientarea camerei, ceea ce îl face extrem de accesibil. Utilizând algoritmi matematici avansați și optimizări hardware, sistemul poate genera modele 3D precise pornind doar de la seturi de imagini consecutive (Wu, 2013). Un aspect important al sistemului este implementarea procesului "Structure-from-Motion" (SfM), care permite identificarea punctelor comune din mai multe imagini și reconstruirea formei reale a obiectelor cu precizie milimetrică. Sistemul dezvoltat demonstrează potențialul fotogrametriei ca metodă standardizată în aplicații industriale (Smith et al., 2016), cu rezultate competitive în termeni de precizie și eficiență (Moulon et al., 2012).

Calitatea și precizia rezultatelor obținute cu sistemul dezvoltat au fost evaluate prin teste practice extensive. Un aspect crucial pentru obținerea unor rezultate optime este controlul precis al parametrilor de scanare. Interfața web dezvoltată cu framework-ul Flask permite ajustarea fină a parametrilor esențiali, incluzând focusul camerei, intensitatea luminoasă a LED-urilor și unghiul de incrementare al motoarelor stepper.

Testele au demonstrat că calitatea scanării este puternic influențată de două aspecte fundamentale: focusul și luminozitatea. Un focus precis este esențial pentru claritatea detaliilor obiectului scanat, permițând senzorilor să detecteze corect contururile și textura suprafeței. Când focusul este necorespunzător, rezultatul scanării poate fi neclar, cu detalii pierdute sau

deformate, afectând fidelitatea modelului 3D. Sistemul de iluminare LED implementat s-a dovedit eficient în reducerea umbrelor dure și a reflexiilor nedorite, contribuind la o calitate superioară a imaginilor capturate și o precizie mai mare în procesul de reconstrucție fotogrammetrică.

Rezultatele experimentale au evidențiat diferențe semnificative în funcție de caracteristicile obiectului scanat. În cazul obiectelor cu suprafețe care prezintă detalii și contraste puternice, sistemul generează modele 3D detaliate și fidele realității. De exemplu, în cazul scanării unei jucării de lemn cu semne și detalii colorate adăugate, contrastul creat a facilitat o mai bună identificare a conturilor și texturilor, rezultând într-o reprezentare mai precisă a suprafeței. În aceste condiții optime, sistemul menține o eroare maximă de doar 1-2 mm.

Limitările dimensionale ale sistemului au fost atent calibrate pentru a optimiza calitatea rezultatelor. Restricția dimensională de 9x9x9 cm asigură că obiectul este complet cuprins în câmpul vizual al camerei și poate fi focalizat uniform pe întreaga suprafață, evitând astfel erorile de scanare cauzate de depășirea zonei utile de lucru. Această limitare, deși restrictivă, s-a dovedit esențială pentru menținerea calității și eficienței procesului de scanare.

Din punct de vedere al îmbunătățirilor hardware, întregul ansamblu a fost proiectat cu atenție în software-ul CAD CATIA V5, oferind un control precis asupra dimensiunilor și geometriei componentelor. Sistemul beneficiază de o bază fixă și o piesă mobilă care susține senzorul de capăt de cursă, concepută pentru reglare ușoară înainte de fixarea definitivă. Această abordare asigură o aliniere corectă cu mecanismul de acționare și o precizie îmbunătățită în funcționare.

În concluzie, sistemul dezvoltat se poziționează favorabil în contextul evoluției continue a fotogrametriei, care se transformă rapid dintr-un instrument dedicat exclusiv cartografiei într-o soluție versatilă, aplicabilă într-o varietate de contexte operaționale și comerciale. Integrarea tot mai frecventă cu tehnologii emergente precum inteligența artificială, realitatea augmentată și digital twin demonstrează potențialul acestei tehnologii în susținerea tranziției spre Industria 4.0. Pe măsură ce tehnologia avansează, fotogrametria devine nu doar mai accesibilă și mai precisă, ci și mai prezentă în viața noastră, reprezentând un exemplu excelent de îmbinare a viziunii științifice cu instrumente moderne și creative. Aplicațiile sale moderne sunt extrem de diverse, de la arhitectură și urbanism până la arheologie și agricultură, iar în domeniul jocurilor video și realității virtuale, contribuie la crearea unor medii digitale tot mai realiste. Prin dezvoltarea acestui sistem open-source performant și accesibil, contribuim la democratizarea tehnologiei de scanare 3D, oferind o soluție care îmbină precizia cu flexibilitatea și costurile reduse, deschizând astfel noi posibilități pentru inovație și dezvoltare în diverse domenii industriale și creative.

### **Limite ale cercetării de față**

În cadrul prezentei cercetări, au fost identificate mai multe limitări și constrângeri care merită a fi menționate pentru o înțelegere completă a contextului și rezultatelor obținute. Una dintre cele mai semnificative limitări este cea dimensională, sistemul fiind proiectat să funcționeze optimal cu obiecte care nu depășesc dimensiunile de 9x9x9 cm. Această restricție, deși aparent restrictivă, a fost implementată în mod deliberat pentru a asigura că obiectul scanat rămâne complet în câmpul vizual al camerei și poate fi focalizat uniform pe întreaga suprafață, evitând astfel erorile de scanare care ar putea apărea din depășirea zonei utile de lucru.

Din punct de vedere al tehnologiei utilizate, trebuie menționat că metoda fotogrammetrică, deși oferă numeroase avantaje în termeni de flexibilitate și costuri, prezintă anumite limitări inerente comparativ cu alte tehnologii de scanare 3D. Spre exemplu, scanarea cu laser oferă o precizie marginal superioară, deși la costuri și complexitate operațională semnificativ mai mari. De asemenea, sistemul este limitat la captarea suprafețelor externe ale obiectelor, neputând furniza informații despre structurile interne.

Un aspect crucial care influențează calitatea rezultatelor este dependența de parametrii de imagine. Testele efectuate au demonstrat că performanța sistemului este puternic influențată de două aspecte fundamentale: focusul și luminozitatea. Un focus imprecis poate duce la pierderea detaliilor sau la deformarea modelului 3D rezultat. Deși sistemul implementează un sistem de iluminare LED pentru a reduce umbrele și reflexiile nedorite, calitatea iluminării rămâne un factor critic în obținerea unor rezultate optime.

O altă limitare semnificativă ține de resursele computaționale necesare. Procesarea seturilor mari de imagini și gestionarea volumelor substanțiale de date generate de scanările de înaltă rezoluție necesită resurse computaționale considerabile. Această provocare devine deosebit de relevantă în contextul unui sistem conceput să fie accesibil și low-cost, putând afecta timpul total necesar pentru obținerea modelului 3D final.

În final, dar nu mai puțin important, trebuie menționat aspectul validării și calibrării sistemului. Calitatea modelelor 3D poate varia semnificativ în funcție de pachetul software utilizat, subliniind importanța unei validări aprofundate și a testelor pilot înainte de implementarea în aplicații critice. Acest aspect necesită o atenție deosebită în procesul de calibrare și ajustare a sistemului pentru menținerea acurateței rezultatelor. Toate aceste limitări, deși semnificative, nu diminuează valoarea sistemului dezvoltat, ci mai degrabă oferă o

perspectivă realistă asupra contextului în care acesta poate fi utilizat eficient și direcțiile potențiale de îmbunătățire pentru cercetări viitoare.

### **Direcții viitoare de cercetare**

Cercetarea prezentă deschide multiple căi de dezvoltare și îmbunătățire pentru sistemul de scanare 3D, evidențiind potențialul semnificativ al tehnologiei fotogrammetrice în contextul actual al digitalizării și automatizării industriale.

O direcție majoră de dezvoltare viitoare o reprezintă integrarea tehnologiilor bazate pe inteligență artificială. În special, implementarea câmpurilor neuronale de radianță (NeRF) și a algoritmilor de învățare profundă promite să aducă îmbunătățiri semnificative în calitatea reconstrucțiilor 3D. Aceste tehnologii permit generarea automată a modelelor 3D de înaltă rezoluție din simple fotografii 2D, reducând semnificativ necesitatea intervenției manuale și minimizând acumularea de erori în proces. Sistemele bazate pe inteligență artificială pot revolutiona modul în care se realizează modelarea 3D avansată, făcând-o mai accesibilă pentru aplicații în animație, realitate augmentată/virtuală și jocuri.

În ceea ce privește procesarea și automatizarea, cercetările viitoare se pot concentra pe dezvoltarea de algoritmi care să permită procesarea în timp real sau aproape în timp real a datelor captate. O provocare importantă rămâne gestionarea scenelor dinamice și a mediilor complexe, precum și îmbunătățirea scalabilității sistemului pentru procesarea eficientă a seturilor mari de date. Aceste optimizări sunt esențiale pentru extinderea aplicabilității sistemului în contexte industriale unde timpul de procesare și precizia sunt critice.

Extinderea domeniilor de aplicare reprezintă o altă direcție promițătoare de cercetare. Sistemul poate fi adaptat pentru utilizare în inspecții industriale și monitorizare la distanță, în special în sectoarele energetic și minier, unde poate contribui la reducerea riscurilor pentru personal și la optimizarea timpului de intervenție. Integrarea cu tehnologii emergente precum realitatea augmentată și conceptul de digital twin deschide noi posibilități în contextul Industriei 4.0. În domeniul medical și al patologiei, dezvoltarea de aplicații specializate poate conduce la îmbunătățiri semnificative în diagnosticare și cercetare.

Din perspectiva optimizărilor tehnice, eforturile viitoare se pot concentra pe îmbunătățirea preciziei mecanice și a calității optice a sistemului. Dezvoltarea unor interfețe mai intuitive și funcționale pentru utilizatori, precum și implementarea unor protocoale de comunicare mai eficiente pentru transferul datelor, sunt aspecte care pot crește semnificativ utilitatea și

accesibilitatea sistemului. Aceste îmbunătățiri tehnice vor contribui la crearea unui sistem mai robust și mai ușor de utilizat.

În final, dar nu mai puțin important, democratizarea tehnologiei rămâne un obiectiv central pentru dezvoltările viitoare. Acest lucru implică crearea de soluții mai accesibile și flexibile, care să poată fi adaptate la diverse contexte operaționale. Dezvoltarea de instrumente educaționale și materiale de training va facilita adoptarea tehnologiei de către un public mai larg, contribuind la răspândirea și evoluția continuă a sistemelor de scanare 3D bazate pe fotogrammetrie.

## 6. BIBLIOGRAFIE

---

- [1] Abdel-Bary, M. (2015). 3D Laser Scanners' Techniques Overview.
- [2] Agarwal, S., Furukawa, Y., Snavely, N., Simon, I., Curless, B., Seitz, S. M., & Szeliski, R. (2011). Building Rome in a day. *Communications of the ACM*, 54(10), 105–112. <https://doi.org/10.1145/2001269.2001293>
- [3] Allegue, P., Melendreras-Ruiz, R., & Torres, M. (2021). Comparative Analysis Between the Main 3D Scanning Techniques: Photogrammetry, Terrestrial Laser Scanner, and Structured Light Scanner in Religious Imagery: The Case of The Holy Christ of the Blood. *ACM Journal on Computing and Cultural Heritage (JOCCH)*, 15, 1-23. <https://doi.org/10.1145/3469126>
- [4] Alharbi, N., & Osman, R. (2022). Influence of scan technology on the accuracy and speed of intraoral scanning systems for the edentulous maxilla: an in vitro study. *Journal of prosthodontics*. <https://doi.org/10.1111/jopr.13633>
- [5] Antonaya-Martín, J., et al. (2023). Accuracy between 2D Photography and Dual-Structured Light 3D Facial Scanner for Facial Anthropometry: A Clinical Study. *Journal of Clinical Medicine*, 12. <https://doi.org/10.3390/jcm12093090>
- [6] Balasubramanian, M., & Sheykhmaleki, P. (2025). Emerging Roles of 3D Body Scanning in Human-Centric Applications. *Technologies*. <https://doi.org/10.3390/technologies13040126>
- [7] Bartoš, K., Pukanská, K., & Sabová, J. (2014). Overview of Available Open-Source Photogrammetric Software, its Use and Analysis. *International journal for innovation education and research*, 2, 62-70
- [8] Belyansky, I., Broda, A., Lu, R., Zahiri, H., Addo, A., & George, P. (2020). Hybrid versus open retromuscular abdominal wall repair: early outcomes. *Surgical Endoscopy*, 35, 5593-5598. <https://doi.org/10.1007/s00464-020-08060-y>
- [9] Briese, C., & Pfeifer, N. (2007). Laser scanning – principles and applications. <https://doi.org/10.3997/2214-4609.201403279>
- [10] Camps, I., Medina-Sotomayor, P., & Pascual-Moscardó, A. (2018). Accuracy of four digital scanners according to scanning strategy in complete-arch impressions. *PLoS ONE*, 13. <https://doi.org/10.1371/journal.pone.0202916>
- [11] Cattrysse, E., Scafoglieri, A., Van Vlasselaer, N., & Keelson, B. (2024). Exploring reliable photogrammetry techniques for 3D modeling in anatomical research and education. *Anatomical Sciences Education*, 17, 674-682. <https://doi.org/10.1002/ase.2391>



- [12] Clark, D., & Badea, C. (2017). Hybrid spectral CT reconstruction. PLoS ONE, 12. <https://doi.org/10.1371/journal.pone.0180324>
- [13] De Dios Cruz, P., Notni, G., Ramm, R., Heist, S., & Kühmstedt, P. (2024). Fusion of Multimodal Imaging and 3D Digitization Using Photogrammetry. Sensors (Basel, Switzerland), 24. <https://doi.org/10.3390/s24072290>
- [14] Deutsch, H., Ryu, W., & Platt, A. (2020). Hybrid decompression and reconstruction technique for cervical spondylotic myelopathy: case series and review of the literature. Journal of spine surgery, 6(1), 181-195. <https://doi.org/10.21037/JSS.2019.12.08>
- [15] Dold, P., Heizmann, M., Hartung, J., & Jahn, A. (2022). Analysis of AI-Based Single-View 3D Reconstruction Methods for an Industrial Application. Sensors (Basel, Switzerland), 22. <https://doi.org/10.3390/s22176425>
- [16] Fan, L., Wang, Z., Lo, Y., Ge, S., Huang, H., & Zhang, C. (2021). Comparison of 3D Reconstruction Methods: Image-Based and Laser-Scanning-Based, 1257-1266. [https://doi.org/10.1007/978-981-15-8892-1\\_88](https://doi.org/10.1007/978-981-15-8892-1_88)
- [17] Forbes, A. (2018). Structured Light from Lasers. Laser & Photonics Reviews, 13. <https://doi.org/10.1002/lpor.201900140>
- [18] Furukawa, Y., & Iturbe, M. (2007). Accurate, Dense, and Robust Multi-View Stereopsis. Computer Vision and Pattern Recognition. <https://doi.org/10.1109/cvpr.2007.383246>
- [19] G, K., & R, S. (2025). Development of deep learning aided surface reconstruction system for dimensional metrology using sheet of light scanning technique. Surface Topography: Metrology and Properties. <https://doi.org/10.1088/2051-672x/add54e>
- [20] Gárdonyi, G., Metzger, M., & Ujvári, Z. (2023). A consistent methodology for forensic photogrammetry scanning of human remains using a single handheld DSLR camera. Forensic Sciences Research, 8, 295-307. <https://doi.org/10.1093/fsr/owad036>
- [21] Grammatikopoulos, L., et al. (2023). Super-Resolution Techniques in Photogrammetric 3D Reconstruction from Close-Range UAV Imagery. Heritage. <https://doi.org/10.3390/heritage6030143>
- [22] Gröning, F., Pérez-Pachón, L., Aliotta, S., Cordoni, S., & Struck, R. (2019). Application of Photogrammetry in Biomedical Science. Advances in experimental medicine and biology, 1120, 121-130. [https://doi.org/10.1007/978-3-030-06070-1\\_10](https://doi.org/10.1007/978-3-030-06070-1_10)

- [23] Haleem, A., & Javaid, M. (2018). 3D scanning applications in medical field: A literature-based review. *Clinical Epidemiology and Global Health*. <https://doi.org/10.1016/J.CEGH.2018.05.006>
- [24] Helle, R., & Lemu, H. (2021). A case study on use of 3D scanning for reverse engineering and quality control. *Materials Today: Proceedings*. <https://doi.org/10.1016/J.MATPR.2021.01.828>
- [25] Hu, C., Kong, L., & Lv, F. (2021). Application of 3D laser scanning technology in engineering field. *E3S Web of Conferences*. <https://doi.org/10.1051/E3SCONF/202123304014>
- [26] Ioannidis, C., & Verykokou, S. (2023). An Overview on Image-Based and Scanner-Based 3D Modeling Technologies. *Sensors (Basel, Switzerland)*, 23. <https://doi.org/10.3390/s23020596>
- [27] Izvozchikova, V., Prishhepa, A., Zykov, A., Mezhenin, A., & Polyakov, V. (2020). Using Virtual Scenes for Comparison of Photogrammetry Software. *Advances in Intelligent Systems, Computer Science and Digital Economics II*. [https://doi.org/10.1007/978-3-030-80478-7\\_7](https://doi.org/10.1007/978-3-030-80478-7_7)
- [28] Jutt, D., et al. (2017). Three-dimensional Imaging and Scanning: Current and Future Applications for Pathology. *Journal of Pathology Informatics*, 8. [https://doi.org/10.4103/jpi.jpi\\_32\\_17](https://doi.org/10.4103/jpi.jpi_32_17)
- [29] Kanchwala, S., & Momeni, A. (2018). Hybrid Prepectoral Breast Reconstruction: A Surgical Approach that Combines the Benefits of Autologous and Implant-Based Reconstruction. *Plastic and Reconstructive Surgery*, 142, 1109–1115. <https://doi.org/10.1097/PRS.0000000000004858>
- [30] Karami, A., Remondino, F., & Menna, F. (2022). Combining Photogrammetry and Photometric Stereo to Achieve Precise and Complete 3D Reconstruction. *Sensors*, 22. <https://doi.org/10.3390/s22218172>
- [31] Khan, M., Akki, S., Zorlubas, B., & Blicharski, P. (2023). Laser beam scanning-based 3D structured light scanner combining a bi-resonant MEMS mirror with low-cost imaging sensor, 12624, 126240L-126240L-14. <https://doi.org/10.1117/12.2675726>
- [32] Krause, K., Goldman, E., Mullins, D., & Kist, M. (2023). Developing 3D models using photogrammetry for virtual reality training in anatomy. *Anatomical Sciences Education*, 16, 1033-1040. <https://doi.org/10.1002/ase.2301>
- [33] Kumar, L., et al. (2022). Exploring the potential of 3D Scanning in Industry 4.0: An Overview. *International Journal of Cognitive Computing in Engineering*. <https://doi.org/10.1016/j.ijcce.2022.08.003>

- [34] Lowe, D. G. (2004). Distinctive Image Features from Scale-Invariant Keypoints. *International Journal of Computer Vision*, 60(2), 91–110. <https://doi.org/10.1023/b:visi.0000029664.99615.94>
- [35] Lu, Y., Li, P., Wang, S., Tang, P., Lu, J., & Fan, S. (2024). Image-based 3D reconstruction for Multi-Scale civil and infrastructure Projects: A review from 2012 to 2022 with new perspective from deep learning methods. *Adv. Eng. Informatics*, 59, 102268. <https://doi.org/10.1016/j.aei.2023.102268>
- [36] Luchowski, L., Tarnawski, M., Tomaka, A., & Pojda, D. (2021). Integration and Application of Multimodal Measurement Techniques: Relevance of Photogrammetry to Orthodontics. *Sensors*, 21. <https://doi.org/10.3390/s21238026>
- [37] Menna, F., Remondino, F., Toschi, I., & Nocerino, E. (2017). A CRITICAL REVIEW OF AUTOMATED PHOTOGRAMMETRIC PROCESSING OF LARGE DATASETS. *ISPRS Archives of the Photogrammetry*, 591-599. <https://doi.org/10.5194/ISPRS-ARCHIVES-XLII-2-W5-591-2017>
- [38] Ming-Kuei Hu. (1962). Visual pattern recognition by moment invariants. *IEEE Transactions on Information Theory*, 8(2), 179–187. <https://doi.org/10.1109/tit.1962.1057692>
- [39] Moulon, P., Monasse, P., & Marlet, R. (2013). Adaptive Structure from Motion with a Contrario Model Estimation. *Computer Vision – ACCV 2012*, 257–270. [https://doi.org/10.1007/978-3-642-37447-0\\_20](https://doi.org/10.1007/978-3-642-37447-0_20)
- [40] Nagy, M., Štempeľová, I., Annuš, N., Dancsa, D., & Takáč, O. (2023). Creating a partial 3D model in selected biological areas using a small number of photographs. *International Journal of Advanced Natural Sciences and Engineering Researches*. <https://doi.org/10.59287/ijanser.917>
- [41] Noardo, F., Chiabrando, F., Aicardi, I., & Lingua, A. (2018). Recent trends in cultural heritage 3D survey: The photogrammetric computer vision approach. *Journal of Cultural Heritage*. <https://doi.org/10.1016/J.CULHER.2017.11.006>
- [42] Onyia, T., Olarinoye, I., & Jimoh, S. (2025). Advancements and Challenges in 3D Scanning. *African Journal of Advances in Science and Technology Research*. <https://doi.org/10.62154/ajastr.2025.018.010640>
- [43] Ozimek, A., Łabędź, P., Ozimek, P., & Skabek, K. (2021). Digital Modelling and Accuracy Verification of a Complex Architectural Object Based on Photogrammetric Reconstruction. *Buildings*, 11, 206. <https://doi.org/10.3390/BUILDINGS11050206>

- [44] Pasini, D., Wu, J., Wyman, O., Wang, W., & Tang, Y. (2024). Multi-view 3D reconstruction based on deep learning: A survey and comparison of methods. *Neurocomputing*, 582, 127553. <https://doi.org/10.1016/j.neucom.2024.127553>
- [45] Pereira, C., & Vermeire, B. (2022). Performance and accuracy of hybridized flux reconstruction schemes. *J. Comput. Phys.*, 457, 111039. <https://doi.org/10.1016/j.jcp.2022.111039>
- [46] Petrie, G., & Toth, C. (2017). Introduction to Laser Ranging, Profiling, and Scanning, 1-28. <https://doi.org/10.1201/9781315154381-1>
- [47] Rainer, G., Drettakis, G., Prakash, S., & Bousseau, A. (2022). Deep scene-scale material estimation from multi-view indoor captures. *Comput. Graph.*, 109, 15-29. <https://doi.org/10.1016/j.cag.2022.09.010>
- [48] Remondino, F., & El-Hakim, S. (2006). Image-based 3D Modelling: A Review. *The Photogrammetric Record*, 21(115), 269–291. <https://doi.org/10.1111/j.1477-9730.2006.00383.x>
- [49] Rodríguez-Martín, M., & Rodríguez-Gonzálvez, P. (2020). Suitability of Automatic Photogrammetric Reconstruction Configurations for Small Archaeological Remains. *Sensors*, 20. <https://doi.org/10.3390/s20102936>
- [50] Ryan, J. (2019). Photogrammetry for 3D Content Development in Serious Games and Simulations
- [51] Samavati, T., & Soryani, M. (2023). Deep learning-based 3D reconstruction: a survey. *Artificial Intelligence Review*, 56, 9175–9219. <https://doi.org/10.1007/s10462-023-10399-2>
- [52] Scholes, S., Sroor, H., Ait-Ameur, K., Forbes, A., & Zhan, Q. (2020). General design principle for structured light lasers. *Optics express*, 28(23), 35006–35017. <https://doi.org/10.1364/oe.410963>
- [53] Schonberger, J. L., & Frahm, J.-M. (2016). Structure-from-Motion Revisited. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). <https://doi.org/10.1109/cvpr.2016.445>
- [54] Schönberger, J. L., Zheng, E., Frahm, J.-M., & Pollefeys, M. (2016). Pixelwise View Selection for Unstructured Multi-View Stereo. *Lecture Notes in Computer Science*, 501–518. [https://doi.org/10.1007/978-3-319-46487-9\\_31](https://doi.org/10.1007/978-3-319-46487-9_31)
- [55] Schroder, W., Braun, D., Douglass, M., Magnani, M., & Reeves, J. (2020). The Digital Revolution to Come: Photogrammetry in Archaeological Practice. *American Antiquity*, 85, 737–760. <https://doi.org/10.1017/aaq.2020.59>

- [56] Scisciola, F., Lombardo, L., Baciliero, M., Pellitteri, F., & Cremonini, F. (2023). Accuracy of 3D facial scans: a comparison of three different scanning system in an in vivo study. *Progress in Orthodontics*, 24. <https://doi.org/10.1186/s40510-023-00496-x>
- [57] Siciliani, G., Lombardo, L., Vogrig, A., Spedicato, G., Albertini, P., & Pellitteri, F. (2022). Comparative analysis of intraoral scanners accuracy using 3D software: an in vivo study. *Progress in Orthodontics*, 23. <https://doi.org/10.1186/s40510-022-00416-5>
- [58] Skabek, K., Nytko, M., Ozimek, P., & Labedz, P. (2021). Histogram Adjustment of Images for Improving Photogrammetric Reconstruction. *Sensors*, 21. <https://doi.org/10.3390/s21144654>
- [59] Skamantzari, M., Pateraki, M., Georgopoulos, A., & Tapinaki, S. (2023). CONVENTIONAL OR AUTOMATED PHOTOGRAMMETRY FOR CULTURAL HERITAGE DOCUMENTATION?. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*. <https://doi.org/10.5194/isprs-archives-xxviii-m-2-2023-1535-2023>
- [60] Smith, M. W., Carrivick, J. L., & Quincey, D. J. (2015). Structure from motion photogrammetry in physical geography. *Progress in Physical Geography: Earth and Environment*, 40(2), 247–275. <https://doi.org/10.1177/0309133315615805>
- [61] Sneha, A. (2025). Crafting Worlds: 3d Animation. *International Journal of Scientific Research and Engineering Trends*. <https://doi.org/10.61137/ijret.vol.11.issue2.431>
- [62] Spiriev, T., et al. (2024). Intraoperative Videogrammetry and Photogrammetry for Photorealistic Neurosurgical 3-Dimensional Models Generated Using Operative Microscope: Technical Note. *Operative Neurosurgery*, 26, 716–726. <https://doi.org/10.1227/ons.0000000000001034>
- [63] T, S., S, V., Msv, B., & Talakayala, P. (2024). Photogrammetry: Insights on 3D Model Generation. *2024 Global Conference on Communications and Information Technologies (GCCIT)*, 1–7. <https://doi.org/10.1109/GCCIT63234.2024.10862214>
- [64] Tao, P., Shan, J., Wang, L., Zhang, S., Hu, Z., & Ji, S. (2020). Toward a unified theoretical framework for photogrammetry. *Geo-spatial Information Science*, 23, 75–86. <https://doi.org/10.1080/10095020.2020.1730712>
- [65] Tao, W., Zhao, H., & Cui, B. (2021). High-Precision 3D Reconstruction for Small-to-Medium-Sized Objects Utilizing Line-Structured Light Scanning: A Review. *Remote. Sens.*, 13, 4457. <https://doi.org/10.3390/rs13214457>

- [66] Turner, E., Cheng, P., & Zakhor, A. (2015). Fast, Automated, Scalable Generation of Textured 3D Models of Indoor Environments. *IEEE Journal of Selected Topics in Signal Processing*, 9, 409-421. <https://doi.org/10.1109/JSTSP.2014.2381153>
- [67] Uesugi, Y., Kozawa, Y., & Sato, S. (2023). Laser Scanning Microscope Techniques with Structured Light Beams Enabling Super-Resolution Imaging and Rapid Three-Dimensional Imaging. *JSAP-Optica Joint Symposia 2023 Abstracts*. [https://doi.org/10.1364/jsapo.2023.23p\\_a310\\_1](https://doi.org/10.1364/jsapo.2023.23p_a310_1)
- [68] Valença, J., Araújo, H., & Júlio, E. (2012). Applications of photogrammetry to structural assessment. *Experimental Techniques*, 36, 71-81. <https://doi.org/10.1111/j.1747-1567.2011.00731.x>
- [69] Wallace, C. (2022). Refinement of retrospective photogrammetry: an approach to 3D modeling of archaeological sites using archival data. *Archaeological and Anthropological Sciences*, 14. <https://doi.org/10.1007/s12520-022-01632-0>
- [70] Walton, S., et al. (2025). Survey on 3D Reconstruction Techniques: Large-Scale Urban City Reconstruction and Requirements. *IEEE transactions on visualization and computer graphics*. <https://doi.org/10.1109/tvcg.2025.3540669>
- [71] Wang, J., Bray, P., Burns, J., Farhan, M., & Cheng, T. (2021). Comparison of 3D scanning versus traditional methods of capturing foot and ankle morphology for the fabrication of orthoses: a systematic review. *Journal of Foot and Ankle Research*, 14, 1-11. <https://doi.org/10.1186/s13047-020-00442-8>
- [72] Wang, X., Han, S., Lai, Z., Jia, Z., Zhang, R., & Zhang, Y. (2024). Fully automated structured light scanning for high-fidelity 3D reconstruction via graph optimization. *Optics express*, 32(6), 9139-9160. <https://doi.org/10.1364/oe.518556>
- [73] Wang, Y., & Liu, J. (2021). 3D surface reconstruction of small height object based on thin structured light scanning. *Micron*, 143, 103022. <https://doi.org/10.1016/j.micron.2021.103022>
- [74] Westoby, M. J., Brasington, J., Glasser, N. F., Hambrey, M. J., & Reynolds, J. M. (2012). "Structure-from-Motion" photogrammetry: A low-cost, effective tool for geoscience applications. *Geomorphology*, 179, 300–314
- [75] Wu, C. (2013). Towards Linear-Time Incremental Structure from Motion. 2013 International Conference on 3D Vision. <https://doi.org/10.1109/3dv.2013.25>

- [76] Yan, Z., Qin, R., Mazzacca, G., Remondino, F., Rigon, S., & Karami, A. (2023). A Critical Analysis of NeRF-Based 3D Reconstruction. *Remote. Sens.*, 15, 3585. <https://doi.org/10.3390/rs15143585>
- [77] Yu, F., Sui, X., Tang, J., Pan, D., & Zeng, L. (2020). Evaluating the accuracy of hand models obtained from two 3D scanning techniques. *Scientific Reports*, 10. <https://doi.org/10.1038/s41598-020-68457-6>
- [78] Zhang, B., Xu, B., Li, J., Xu, C., Liu, K., & Ji, Y. (2024). Simple modulation of Lissajous MEMS laser beam scanning with reconfigurable structured light patterns for 3D imaging. *Optics express*, 32(8), 13249-13265. <https://doi.org/10.1364/oe.518283>
- [79] Zhang, C., & Maga, A. (2023). An Open-Source Photogrammetry Workflow for Reconstructing 3D Models. *Integrative Organismal Biology*, 5. <https://doi.org/10.1093/iob/obad024>
- [80] Zhou, L., Chen, X., Hu, H., Zuo, Y., & Wu, G. (2024). A Comprehensive Review of Vision-Based 3D Reconstruction Methods. *Sensors* (Basel, Switzerland), 24. <https://doi.org/10.3390/s24072314>

Proiectul se concentrează pe dezvoltarea unui sistem de scanare 3D bazat pe tehnologia fotogrammetriei. Obiectivul principal este demonstrarea funcționalității unui sistem adaptat care păstrează configurația hardware de bază, dar implementează o soluție avansată de procesare fotogrammetrică utilizând software-ul COLMAP.

În ceea ce privește dezvoltarea hardware, proiectul implică proiectarea și modificarea componentelor pentru scanare 3D, incluzând integrarea camerei, motoarelor și structurii mecanice. Un accent deosebit se pune pe optimizarea preciziei mecanice și a calității optice pentru a asigura rezultate optime. Componenta software a proiectului cuprinde configurarea sistemului de operare Raspberry Pi, integrarea bibliotecilor necesare pentru cameră și implementarea protocoalelor de comunicare. O interfață de control bazată pe Flask a fost dezvoltată pentru a facilita operarea sistemului.

Procesul de achiziție a datelor reprezintă un aspect crucial, care implică controlul sincronizat al motoarelor și camerei, precum și gestionarea eficientă a transferului de imagini către stația de procesare. Această etapă este fundamentală pentru calitatea rezultatelor finale. Procesarea fotogrammetrică constituie nucleul proiectului, implementând pipeline-ul de reconstrucție COLMAP. Acesta include extragerea și potrivirea caracteristicilor, estimarea poziției camerei, precum și etapele de reconstrucție rară și densă, culminând cu generarea mesh-ului final.

Soluția dezvoltată reprezintă o alternativă competitivă și flexibilă la sistemele comerciale, combinând componente hardware accesibile cu algoritmi fotogrammetrici avansați. Sistemul oferă capacitatea de a realiza scanări 3D detaliate și reproductibile, menținând un echilibru optim între precizie mecanică, calitate optică și stabilitate operațională.



This research presents the development of a 3D scanning system based on photogrammetric technology. The main objective is to demonstrate the functionality of an adapted system that maintains basic hardware configuration while implementing an advanced photogrammetric processing solution using COLMAP software.

The system integrates both hardware and software components, including hardware configuration utilizing Raspberry Pi 4B, stepper motors, and a high-resolution camera; software implementation featuring a Flask-based web control interface; and an automated photogrammetric reconstruction pipeline using COLMAP.

The reconstruction process is fully automated and implements Structure-from-Motion (SfM) technology, allowing for precise identification of common points across multiple images and achieving millimeter-level accuracy in 3D reconstruction. The system can identify between 10,000 and 50,000 points of interest in high-resolution images (4000x3000 pixels), strategically distributed across textured areas. Key innovations include integration of automated image acquisition with advanced photogrammetric processing, implementation of a controlled LED lighting system to reduce shadows and unwanted reflections, optimization of scanning parameters through a web-based interface, and dimensional constraints of 9x9x9m to ensure optimal focus and visual field coverage.

The developed system represents a competitive and flexible alternative to commercial solutions, combining affordable hardware components with advanced photogrammetric algorithms. Experimental results show high accuracy, with maximum errors of only 1-2mm under optimal conditions.

# DECLARAȚIE PRIVIND ORIGINALITATEA

---

LUCRĂRII DE LICENȚĂ / PROIECTULUI DE DIPLOMĂ / DISERTAȚIEI

UNIVERSITATEA TRANSILVANIA DIN BRAȘOV

FACULTATEA DE INGINERIE ELECTRICĂ ȘI ȘTIINȚA CALCULATOARELOR

PROGRAMUL DE STUDII ROBOTICĂ

NUMELE ȘI PRENUMELE JUGARIU MATTIAS-MARIAN

PROMOȚIA 2021-2025

SESIUNEA VARĂ 2025

TEMA LUCRĂRII / PROIECTULUI/ DISERTAȚIEI

3D SCANNER

CONDUCĂTOR ȘTIINȚIFIC COCIAȘ TIBERIU TEODOR

Declar pe propria răspundere că lucrarea de față este rezultatul muncii proprii, pe baza cercetărilor proprii și pe baza informațiilor obținute din surse care au fost citate și indicate conform normelor etice, în textul lucrării/proiectului, în note și în bibliografie.

Declar că nu s-a folosit în mod tacit sau ilegal munca altora și că nici o parte din teză/proiect nu încalcă drepturile de proprietate intelectuală ale altcuiva, persoană fizică sau juridică.

Declar că lucrarea/ proiectul nu a mai fost prezentat(ă) sub această formă vreunei instituții de învățământ superior în vederea obținerii unui grad sau titlu științific ori didactic.

În cazul constatării ulterioare a unor declarații false, voi suporta rigorile legii.

Data: 21.06.2025

Absolvent

JUGARIU MATTIAS MARIAN